

我先把这篇笔记按“算法在做什么 → 为什么这样分析 → 每个定理在说什么 → 结论意味着什么”拆开讲。你要是更想看“逐页精读”或“只讲 heavy-tail 部分”，我也可以接着按那个方式展开。

我已经把核心链路理顺了：这份文档其实在做三件事——先定义带 Nesterov 动量的 Muon 更新，再分析“精确 polar 分解 + heavy-tail 噪声”，最后分析“近似 polar 分解”会把结论劣化多少。里面还有一段“旧分析”当作对照。

Thought for 1m 47s >

这篇文稿本质上是在给 带 Nesterov 动量的 Muon 优化器做一套理论说明。全文分成四块：A 部分先定义算法和基本假设；B 部分研究“精确 polar 分解 + heavy-tailed 随机噪声”时的收敛；C 部分研究“近似 polar 分解”会怎样影响结论；D 部分则回顾一套更早的分析框架。它更像研究笔记而不是最终定稿论文，首页标题就是“Notes of Muon Optimizer”，并标注为 ICLR 2026 双盲评审稿。  MuonNesterov

先看算法本身。文中把优化目标写成最小化矩阵变量 $X \in \mathbb{R}^{d \times d}$ 上的函数 $f(X)$ 。带 Nesterov 动量的 Muon 更新是

$$C_k = \beta C_{k-1} + G_k, \quad M_k = \beta C_k + G_k, \quad X_{k+1} = X_k - \eta T(M_k).$$

这里 G_k 是梯度估计， β 是动量系数， η 是步长， $T(M_k)$ 是对 M_k 做 polar decomposition 后得到的“方向”。A 部分同时假设了 f 的 L -smooth、 μ -strongly convex，以及随机梯度无偏、方差有界或更一般的 α -阶矩有界。也就是说，整篇文稿的核心对象不是普通 SGD，而是“先做动量累积，再把矩阵方向投影到 polar 因子上”的更新。  MuonNesterov

直觉上，Muon 和普通梯度法最大的不同，是它不直接沿着 M_k 的长度信息走，而是沿着 M_k 的 polar 正交因子 $O(M_k)$ 走。对于矩阵 $M_k = UV^\top$ ，polar 因子相当于 $UV^\top$ ：保留“左右奇异向量给出的方向结构”，但把奇异值都压到 1。这样做有两个分析上的好处。第一， $O(M_k)$ 是正交矩阵（或正交因子），其 Frobenius 范数固定为 $\sqrt{d}$ ，所以每一步位移长度是固定的： $\|X_{k+1} - X_k\|_F = \eta\sqrt{d}$ 。第二，内积 $\langle M_k, O(M_k) \rangle$ 恰好等于核范数 $\|M_k\|_*$ ，从而能把“朝下降方向前进了多少”写成一个很干净的量。B.3 和 C.1 的推导都在用这两个性质。  MuonNesterov  MuonNesterov

A 部分之后，作者先进入 heavy-tail 噪声分析。这里最关键的假设是：单样本随机梯度 G_k^i 不是只要求二阶矩有界，而是只要求 $\alpha \in (1, 2]$ 阶矩有界，并且这个噪声上界还允许依赖真梯度大小：

$$\mathbb{E}[\|G_k^i - \nabla f(X_k)\|_F^\alpha \mid X_k] \leq \sigma_0^\alpha + \sigma_1^\alpha \|\nabla f(X_k)\|_F^\alpha.$$

这表示噪声可能是重尾的，甚至方差都不一定好控制。然后作者证明：把 B 个样本平均成 batch 梯度 G_k 后，噪声的 α -矩会缩小到 $B^{-(\alpha-1)}$ 这个量级。换句话说，batch 越大，heavy-tail 噪声的影响越弱，但衰减速度取决于 α ，而不是标准有限方差情形里的 $1/B$ 。  MuonNesterov

B 部分的主线是：先把 Muon 的真实更新方向和真梯度之间的偏差单独拎出来分析。文中一会儿把它写成 ϵ_k ，一会儿写成 $S_k = M_k - \nabla f(X_k)$ 。这类误差由三部分组成：一是动量历史叠加带来的“漂移”，二是相邻梯度变化 $\nabla f(X_{k-1}) - \nabla f(X_k)$ 带来的“动态误差”，三是随机噪声 $\xi_k = G_k - \nabla f(X_k)$ 。B.4 和 B.5 的递推式本质上是在说：Muon 的困难不在一步更新，而在于动量把过去的噪声和过去的梯度变化都带进来了，所以必须证明这个累计误差不会压过下降项。  MuonNesterov

B.6 给出的一个代表性结论是：在合适条件下，平均梯度范数

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F$$

可以被几类项控制：初始化误差项、步长项、动量误差项，以及 heavy-tail 噪声项。尤其重要的是文中定义的

$$\rho = 1 - (1 + \sqrt{d}) \frac{\kappa_\alpha \sigma_1}{B^{(\alpha-1)/\alpha}},$$

它必须为正，才能把误差项“吸收到左边”。这说明如果噪声和梯度大小耦合得太强（ σ_1 大），就必须把 batch B 选得更大，否则理论上不能保证净下降。也就是说，**重尾 + 维度 d + 动量误差**共同决定了 batch 下界。

☞ MuonNesterov

文中随后两次讨论 sample complexity。核心结论一致：为了把平均梯度范数压到 $O(\varepsilon)$ ，可以取 $K = O(\varepsilon^{-2})$ ，并让 batch 大小满足 $B = O(\varepsilon^{-\alpha/(\alpha-1)})$ ，于是总样本复杂度

$$K \times B = O\left(\varepsilon^{-2-\alpha/(\alpha-1)}\right) = O\left(\varepsilon^{-(3\alpha-2)/(\alpha-1)}\right).$$

当 $\alpha = 2$ 时，这退化成 $O(\varepsilon^{-4})$ 。直观解释是：当噪声越接近有限方差情形（ $\alpha \rightarrow 2$ ），所需 batch 增长越温和；当噪声越重尾（ $\alpha \rightarrow 1^+$ ），为了稳定训练就得付出更高的样本代价。 ☞ MuonNesterov ☞ MuonNesterov

B.7 到 B.10 可以看作另一条、更系统的 exact polar 分析线。B.7 先建立一个一阶下降不等式：累计下降量受三部分控制——初始函数值差、每步的平滑性损失 $dL\eta_k^2/2$ 、以及累计误差 $\|M_k - \nabla f(X_k)\|_F$ 。B.8 和 B.9 再把这个误差展开成一串衰减的历史梯度项和噪声项。最后 B.10 得到更一般的结论：只要 batch 足够大、动量 β 足够小，使得

$$\rho := 1 - (1 + \sqrt{d})\left(\beta + \frac{2\sqrt{\pi}C_\alpha\sigma_1}{B^{(\alpha-1)/\alpha}(1-\beta)}\right) > 0,$$

那么平均梯度范数就能被 $1/(\eta K)$ 、 η 、 $B^{-(\alpha-1)/\alpha}$ 、以及初始化残差 $(1-\beta)^{-1}K^{-1}$ 这些项控制。翻成白话：**Muon 能收敛，但前提是动量别太激进、batch 要足够大、近似误差别太大。** ☞ MuonNesterov

C 部分把“精确 polar 分解”放宽成“近似 polar 分解”。作者假设算法实际用的是 $T(M_k)$ ，它与真实 polar 因子 $O(M_k)$ 的误差满足 $\|T(M_k) - O(M_k)\|_F \leq \Delta_k$ 。Theorem C.1 的结论很直观：原本理想情况下的主下降项是 $\eta\|M_k\|_*$ ，现在会被打折成 $\eta(1 - \Delta_k)\|M_k\|_*$ ；同时，误差放大项从原来的 $\sqrt{d}$ 变成 $\sqrt{d} + \Delta_k$ 。所以 Δ_k 越大，真正的下降越少，噪声/偏差项越显著。 ☞ MuonNesterov

Theorem C.2 则把这个结论累积到 K 步，得到

$$\eta(1 - \Delta) \sum_{k=0}^{K-1} \mathbb{E}\|\nabla f(X_k)\|_*$$

被函数值差、累计偏差 $\|\nabla f(X_k) - M_k\|_*$ 、以及平滑性项控制，其中 $\Delta_k \leq \Delta < 1$ 。这意味着：**只要 polar 近似误差始终小于 1，并且不要太接近 1，Muon 的下降分析仍能成立，只是常数变差。**这正好解释了为什么实践里用 Newton-Schulz 或 PolarExpress 近似 polar decomposition 时，理论上要单独跟踪近似误差。 ☞ MuonNesterov

C.3 到 C.6 进一步在有限方差和 α -moment 两种设定下，给出 $\|S_k\|_*$ 或 $\|S_k\|_*^\alpha$ 的总和界。它们的共同思想是：先写出 $S_k = \beta C_k + \xi_k$ ，再用一种统一的 Young 不等式把“动量状态 C_k ”和“随机噪声 ξ_k ”分开控制，最后把所有历史项压成几何级数。Theorem C.4 的信息是：如果 β 足够小，使得某个

$$\rho = (1 - \Delta) - (\text{与 } \beta, d, \varepsilon \text{ 有关的项})$$

仍为正，那么最小梯度范数可以被 $1/(\eta K)$ 、 η 、噪声方差和初始动量状态控制。换句话说，**近似 polar 分解并不会毁掉收敛，只会把允许的动量范围压缩得更严格。** ☞ MuonNesterov

D 部分“Previous Analysis”更像是作者在解释旧思路为什么不够精细。那套分析先研究 $\|X_{k+1} - X^*\|_F^2$ 的递推，再把 $\|T(M_k) - G_k\|_F^2$ 分成三块：一是近似 polar 的数值误差 $T(M_k) - O(M_k)$ ，二是 polar 操作本身对矩阵的几何扭曲 $O(M_k) - M_k$ ，三是动量引入的漂移 $M_k - G_k$ 。这套分解没有错，但它把很多结构都粗糙地混在一起了；相比之下，B、C 两部分的新分析直接盯着 $M_k - \nabla f(X_k)$ 或 S_k ，更贴近 Muon 的真实机制。 ☞ MuonNesterov

如果把整篇文稿压成一句话，它的核心结论就是：**Muon + Nesterov 动量之所以能分析，是因为 polar 因子给了你一个“固定步长长度、方向由奇异向量决定”的更新；真正的理论难点在于动量累积误差和 heavy-tail 噪声，而 batch 大小、动量系数、以及 polar 近似精度，正是控制这些误差能否被吸收的三个关键旋钮。**

☞ MuonNesterov

☞ MuonNesterov

☞ MuonNesterov

这份文件是：[MuonNesterov.pdf](#) ☞ MuonNesterov

接下来你若想继续，我可以直接做两种之一：

1. 把 Theorem B.10 按证明步骤逐行拆开；
2. 专门解释“为什么 polar decomposition 会比直接用梯度更合理”。

Sources

📄 🍏 📌 ⬆️ ↺ ...

Assumption B.1 为什么是 heavy tailed noises

Thought for 11s >

因为 Assumption B.1 只要求噪声有 $\alpha \in (1, 2]$ 阶矩，而不是二阶矩（方差）有界。这正是 heavy-tailed 分析里很常见的建模方式。文中写的是，对每个样本梯度 G_k^i ，有

$$\mathbb{E}[\|G_k^i - \nabla f(X_k)\|_F^\alpha | X_k] \leq \sigma_0^\alpha + \sigma_1^\alpha \|\nabla f(X_k)\|_F^\alpha, \quad \alpha \in (1, 2].$$

并且作者直接把这条假设命名为 “Generalized Heavy-Tailed Noises”。
[MuonNesterov](#)

更具体地说，之所以叫 heavy-tailed，有三个原因。

第一，它比“有界方差”更弱。

如果只知道 $\alpha < 2$ 阶矩有界，并不能推出二阶矩有界。也就是说，当 $\alpha < 2$ 时，噪声分布完全可能是“方差无穷”的，这正是 heavy-tail 场景最典型的特征之一。相反，经典随机优化通常假设

$$\mathbb{E}\|G_k - \nabla f(X_k)\|_F^2 \leq \sigma^2,$$

这是有限方差设定，不是 heavy-tail 设定。文稿在 A.3 里给了 bounded variance 假设，而 B.1 明显换成了更弱的 α -moment 假设。
[MuonNesterov](#) [MuonNesterov](#)

第二， $\alpha \in (1, 2]$ 正是“重尾强度”的参数化方式。

- 当 $\alpha = 2$ 时，它退回到比较接近有限方差的情形。
- 当 $\alpha < 2$ 时，尾部更重，允许更极端的离群噪声。
- α 越接近 1，允许的尾部越重。

所以这里不是在说“某个具体分布一定是帕累托分布之类”，而是在说：噪声只满足低阶矩控制，因此允许重尾行为。这也是为什么后面 sample complexity 会显式依赖 α ，并且在 $\alpha = 2$ 时退化到更标准的结果。

[MuonNesterov](#) [MuonNesterov](#)

第三，作者这里其实用的是 generalized heavy-tailed noise，比普通“加性重尾噪声”还广一点。右边不是单纯常数 σ^α ，而是

$$\sigma_0^\alpha + \sigma_1^\alpha \|\nabla f(X_k)\|_F^\alpha.$$

这表示噪声大小可以随着当前位置的梯度大小一起变大，所以它不仅允许重尾，还允许一种与信号强度耦合的重尾噪声。因此作者才加了 “Generalized” 这个词。
[MuonNesterov](#)

你也可以把它和 A.3 对比着记：

- A.3: bounded variance

$$\mathbb{E}\|G_k - \nabla f(X_k)\|_F^2 \leq \sigma^2$$

这是普通随机优化最常见假设。
[MuonNesterov](#)

- B.1: only α -moment bounded, $\alpha \leq 2$

允许二阶矩不存在，因此属于 heavy-tail 建模。
[MuonNesterov](#)

所以最短的回答是：

B.1 被称为 heavy-tailed noises，不是因为它明确写了“尾分布长什么样”，而是因为它只要求 $\alpha \in (1, 2]$ 阶矩有界；当 $\alpha < 2$ 时，方差可以不存在，这正是 heavy-tail 噪声的标准理论刻画。

另外，你写的 “nioses” 应该是 “noises”。

要的话，我下一条可以继续给你讲：为什么 B.1 能推出 Lemma B.2 里的 $B^{-(\alpha-1)}$ 缩放。

Sources

📄 🌟 🔍 ↶ ↷ ...

lemma B.3说了啥

Thought for a couple of seconds

Lemma B.3 在说：

如果目标函数 f 是 L -smooth，那么 Muon 的前 K 步里，累计的梯度范数总和，可以被“初始函数差值 + 步长造成的平滑性损失 + 方向误差累计”控制住。文中写成

$$\eta \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F \leq (f(X_0) - f^*) + \frac{Ld}{2} K \eta^2 + \eta(1 + \sqrt{d}) \sum_{k=0}^{K-1} \mathbb{E} \|\epsilon_k\|_F.$$

这里 ϵ_k 是更新方向和真梯度之间的偏差项。📄 MuonNesterov

它的含义可以拆成三层。

第一层，**左边是什么**。

左边是

$$\eta \sum_k \mathbb{E} \|\nabla f(X_k)\|_F,$$

也就是“整个训练过程中，平均来说你遇到的梯度到底有多大”。如果这个量小，就说明算法逐渐走到了梯度较小的位置，所以这是一个很标准的“收敛度量”。📄 MuonNesterov

第二层，**右边三项分别代表什么**。

- $f(X_0) - f^*$ ：你一开始离最优值有多远。
- $\frac{Ld}{2} K \eta^2$ ：因为每步走了固定长度 $\eta\sqrt{d}$ ，平滑性会带来一个二次误差代价。
- $\eta(1 + \sqrt{d}) \sum_k \mathbb{E} \|\epsilon_k\|_F$ ：如果 Muon 的方向 M_k 和真梯度 $\nabla f(X_k)$ 差得很多，这个误差会累积，慢慢下降。📄 MuonNesterov

第三层，**它为什么重要**。

这个引理其实是后面整个 B 部分的“总入口”。因为它告诉你：

想证明 Muon 收敛，不需要直接一步一步硬证每步都很好，只要能把误差项 ϵ_k 控住，整体梯度平均值就能控住。

所以后面的 Lemma B.4、B.5、Theorem B.6，本质上都在干同一件事：**估计 ϵ_k 到底有多大**。一旦把 ϵ_k 上界代回 B.3，就能得到最终的收敛率。📄 MuonNesterov

再直白一点，Lemma B.3 的意思就是：

Muon 的整体下降效果 = 理想下降效果 - 平滑性损失 - 动量/随机噪声带来的方向误差。

如果 ϵ_k 很小，Muon 就接近“沿着真实梯度在下降”；如果 ϵ_k 很大，下降就会被污染。📄 MuonNesterov

顺便说一下，这个引理里有个很关键的小观察：因为 polar 因子是正交的，所以

$$\|O(M_k)\|_F = \sqrt{d}, \quad \|X_{k+1} - X_k\|_F = \eta\sqrt{d}.$$

这就是为什么右边会出现 d 和 $\sqrt{d}$ 这些维度因子。  MuonNesterov

你要的话，我下一条可以直接把 Lemma B.3 的证明每一行翻译成白话。

Sources

     ...

lemma B.4说了啥

Thought for 8s

Lemma B.4 说的是：

Muon with Nesterov momentum 的“方向误差” ϵ_k ，可以被精确地展开成三部分：初始误差、梯度漂移累积、以及噪声累积。文中给出的公式是

$$\epsilon_k = \beta^k \epsilon_0 + \beta^2 \sum_{s=1}^k \beta^{k-s} D_s + (1 - \beta) \left((1 + \beta) \xi_k + \sum_{s=1}^{k-1} \beta^{k+1-s} \xi_s - \beta^k \xi_0 \right),$$

其中

$$D_k := \nabla f(X_{k-1}) - \nabla f(X_k), \quad \xi_k := G_k - \nabla f(X_k).$$

 MuonNesterov

这句话翻成白话，就是：

第 k 步时，Muon 用的那个方向和真梯度之间差了多少，不是随机冒出来的，而是由过去一路“递推”积累出来的。

可以拆成 3 块来看。

第一块， $\beta^k \epsilon_0$ ：

这是**初始误差的遗留**。如果一开始就有偏差，那它会被动量系数 β 几何衰减地带到后面去。也就是说，时间越久，这部分影响越小。  MuonNesterov

第二块，

$$\beta^2 \sum_{s=1}^k \beta^{k-s} D_s$$

这是**梯度本身在变动带来的误差**。因为 Muon 有动量，它会记住过去的梯度信息；但真梯度 $\nabla f(X_k)$ 会随着位置变化，所以旧信息会“过时”。 $D_s = \nabla f(X_{s-1}) - \nabla f(X_s)$ 正是在量化这种“梯度漂移”。如果目标函数变化平缓、步子不大，那么这项就小。  MuonNesterov

第三块，

$$(1 - \beta) \left((1 + \beta) \xi_k + \sum_{s=1}^{k-1} \beta^{k+1-s} \xi_s - \beta^k \xi_0 \right)$$

这是**随机噪声通过动量系统传递后的总影响**。这里的 $\xi_k = G_k - \nabla f(X_k)$ 是第 k 步的随机梯度噪声。这个式子说明：当前误差不只受当前噪声影响，还受以前所有噪声影响，只不过越早的噪声权重越小，因为前面乘了 β^{k+1-s} 。所以动量相当于对历史噪声做了一个带衰减的滤波。  MuonNesterov

这个 lemma 为什么重要？

因为它把 ϵ_k 的来源彻底拆开了。后面的 Lemma B.5 就能分别去估计：

- 初始误差项会不会衰减；

- 梯度漂移项能不能用 smoothness 控住；
- 噪声累积项在 heavy-tail 假设下有多大。

也就是说，B.4 是“误差分解公式”，B.5 是“对这个误差分解做上界”。  MuonNesterov

再说一下证明思路，也很值得记：

作者先把动量变量 rescale 一下，定义

$$\widetilde{C}_k = (1 - \beta)C_k, \quad \widetilde{M}_k = (1 - \beta)M_k,$$

然后把 $\widetilde{M}_k$ 写成 $\widetilde{M}_{k-1}$ 、当前噪声、上一时刻噪声、以及梯度变化的递推式，得到一个很干净的关系：

$$\epsilon_k = \beta\epsilon_{k-1} + \beta^2 D_k + (1 - \beta)((1 + \beta)\xi_k - \beta\xi_{k-1}).$$

再把这个递推式展开，就得到最后的闭式表达。  MuonNesterov

所以最短总结是：

Lemma B.4 说明：Muon 的方向误差 ϵ_k = 初始误差衰减 + 梯度变化造成的漂移 + 历史随机噪声的衰减累积。

你要的话，我下一条可以直接继续讲 Lemma B.5 是怎么从 B.4 推出 $\mathbb{E}\|\epsilon_k\|_F$ 上界的。

Sources

     ...

lemma B.5说了啥

Thought for 5s

Lemma B.5 说的是：

在 heavy-tail 噪声假设下，第 k 步的方向误差 ϵ_k 的期望大小，可以被分成几项来上界：初始误差衰减项、由函数平滑性导致的“梯度漂移”项、纯噪声底噪项，以及一个和历史梯度大小耦合的项。文中写成

$$\mathbb{E}\|\epsilon_k\|_F \leq \beta^k \mathbb{E}\|\epsilon_0\|_F + \frac{\beta^2}{1 - \beta} L \eta \sqrt{d} + \frac{\kappa_\alpha \Gamma_\alpha}{B^{(\alpha-1)/\alpha}} \sigma_0 (1 - \beta)^{(\alpha-1)/\alpha} + \frac{\kappa_\alpha \sigma_1}{B^{(\alpha-1)/\alpha}} (1 - \beta) \left((1 + \beta) \mathbb{E}\|\nabla f(X_k)\|_F + \sum_{s=1}^{k-1} \beta^{k-s} \right)$$

 MuonNesterov

可以把它理解成对 Lemma B.4 的“定量版解释”。

1. 第一项：初始误差会几何衰减

$$\beta^k \mathbb{E}\|\epsilon_0\|_F$$

这表示如果一开始动量方向就有误差，那么它会随着步数按 β^k 逐渐消失。也就是说，旧误差不会永久留着。

 MuonNesterov

2. 第二项：梯度变化带来的漂移

$$\frac{\beta^2}{1 - \beta} L \eta \sqrt{d}$$

这一项来自 B.4 里的

$$D_s = \nabla f(X_{s-1}) - \nabla f(X_s).$$

因为 f 是 L -smooth，而且每一步更新长度固定为 $\eta\sqrt{d}$ ，所以

$$\|D_s\|_F \leq L\|X_s - X_{s-1}\|_F = L\eta\sqrt{d}.$$

所以历史梯度变化累积起来，最后变成一个和 L, η, β, d 有关的项。直观上它表示：**动量记住的是过去的梯度，如果真梯度变化太快，就会产生“过时信息”的偏差。**  MuonNesterov

3. 第三项：纯 heavy-tail 底噪

$$\frac{\kappa_\alpha \Gamma_\alpha}{B^{(\alpha-1)/\alpha}} \sigma_0 (1 - \beta)^{(\alpha-1)/\alpha}$$

这是噪声里和真梯度无关的部分。
最重要的信息是它前面有

$$B^{-(\alpha-1)/\alpha},$$

说明 **batch 越大，这部分噪声越小**；而 α 越小，下降得越慢，表示尾巴越重越难平均掉。这个正是 heavy-tail 分析的核心特征。  MuonNesterov

4. 第四项：和梯度大小耦合的噪声

$$\frac{\kappa_\alpha \sigma_1}{B^{(\alpha-1)/\alpha}} (1 - \beta) (\dots)$$

这里的 σ_1 对应 B.1 里噪声上界中的“梯度相关”部分。它说明：
如果当前位置的真梯度本身很大，那么噪声也可能更大；这种噪声不仅影响当前，还会通过动量把过去各步的梯度都带进来。
所以这项里面出现了当前梯度 $\|\nabla f(X_k)\|$ 、历史梯度和初始梯度。  MuonNesterov  MuonNesterov

这个 lemma 的核心意义

它其实是在回答一个问题：

Muon 的更新方向 M_k 和真梯度 $\nabla f(X_k)$ 到底会差多少？

B.5 的答案是：这个误差不是没法控，而是能被上面四类因素控制住。这样一来，就可以把这个上界代回 Lemma B.3，进而得到整个算法的收敛结论。换句话说：

- B.4：把误差 ϵ_k 展开；
- B.5：给这个误差一个可计算上界；
- B.6：再把它代回下降不等式，推出平均梯度收敛率。  MuonNesterov  MuonNesterov  MuonNesterov

一句话总结

Lemma B.5 说：Muon 的方向误差可以被控制，而且它主要由四件事决定——初始误差、梯度变化速度、heavy-tail 底噪、以及与梯度大小耦合的噪声；batch 大会减小噪声项，动量太大会放大历史累积。

你要的话，我下一条可以直接把 Lemma B.5 的证明按每一步推导顺下来。

Sources

     ...

Theorem B.6

Thought for a couple of seconds

Theorem B.6 说的是：

在前面把单步下降（Lemma B.3）和误差上界（Lemma B.5）合起来之后，可以得到 Muon with Nesterov momentum 的一个“平均梯度范数收敛界”。具体地，文中定义

$$\rho := 1 - \frac{(1 + \sqrt{d})\kappa_\alpha\sigma_1}{B^{(\alpha-1)/\alpha}},$$

然后给出

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F \leq \frac{f(X_0) - f^*}{\eta K \rho} + \frac{Ld}{2\rho} \eta + \frac{1 + \sqrt{d}}{\rho} \left[\frac{\mathbb{E} \|\epsilon_0\|_F}{K(1 - \beta)} + \frac{\beta^2}{1 - \beta} L \eta \sqrt{d} + \frac{\kappa_\alpha \Gamma_\alpha}{B^{(\alpha-1)/\alpha}} \sigma_0 (1 - \beta)^{(\alpha-1)/\alpha} + \frac{\kappa}{B^c} \right]$$

也就是：**前 K 步的平均梯度大小，可以被初始化误差、步长、动量、batch 大小、heavy-tail 噪声强度一起控制。**  MuonNesterov

怎么理解这个定理，可以拆成四层。

第一层，它给的是一个什么类型的结论。

这不是“函数值线性收敛”，也不是“最后一步一定很小”，而是一个标准的**非凸/随机优化风格的平均梯度范数界**。平均梯度小，意味着算法在大多数步上已经走到了“比较平”的区域，所以这是证明收敛到近似 stationary point 的常见方式。  MuonNesterov

第二层， ρ 是这条定理里最关键的稳定性参数。

$$\rho = 1 - \frac{(1 + \sqrt{d})\kappa_\alpha\sigma_1}{B^{(\alpha-1)/\alpha}}.$$

如果 $\rho > 0$ ，说明“梯度相关噪声”那部分没有大到把主下降项完全吃掉；如果 $\rho \leq 0$ ，这套界就失效了。直观上就是：

- B 越大， ρ 越大，更稳定；
- σ_1 越大， ρ 越小，说明噪声越依赖梯度，越难控；
- d 越大， $(1 + \sqrt{d})$ 越大，也更苛刻。

所以 Theorem B.6 的一个核心信息是：**要让 Muon 在 heavy-tail 场景下可分析，batch 不能太小。**

 MuonNesterov

第三层，右边每一项分别代表什么。

$$\frac{f(X_0) - f^*}{\eta K \rho}$$

这是初始函数差造成的项。 K 越大它越小，说明迭代久了会摊薄初始误差。  MuonNesterov

$$\frac{Ld}{2\rho} \eta$$

这是平滑性项。步长 η 太大，这项会变大，所以不能盲目增大步长。  MuonNesterov

$$\frac{\mathbb{E} \|\epsilon_0\|_F}{K(1 - \beta)}$$

这是初始方向误差项。虽然有 $1/K$ 衰减，但也被 $1/(1 - \beta)$ 放大，所以 β 太接近 1 时，**历史误差更难消掉**。  MuonNesterov

$$\frac{\beta^2}{1 - \beta} L \eta \sqrt{d}$$

这是动量带来的“梯度漂移代价”。因为动量记住了旧梯度，而真实梯度会变，所以 β 越大，这项越重。

 MuonNesterov

$$\frac{\kappa_\alpha \Gamma_\alpha}{B^{(\alpha-1)/\alpha}} \sigma_0 (1 - \beta)^{(\alpha-1)/\alpha}$$

这是和梯度无关的 heavy-tail 底噪项。重要的是它随 batch 按 $B^{-(\alpha-1)/\alpha}$ 下降。  MuonNesterov

$$\frac{\kappa_\alpha \sigma_1}{B^{(\alpha-1)/\alpha}} \frac{\|\nabla f(X_0)\|_F}{K}$$

这是和梯度耦合的噪声留下的初始化残差。随 K 下降，但同样依赖 batch。  MuonNesterov

第四层，这个定理是怎么来的。
证明思路很清楚：

1. 先用 Lemma B.3，把累计梯度范数和累计误差 $\sum_k \mathbb{E} \|\epsilon_k\|_F$ 联系起来。  MuonNesterov
2. 再用 Lemma B.5，对每个 $\mathbb{E} \|\epsilon_k\|_F$ 做上界。  MuonNesterov
3. 把这些项对 k 从 0 到 $K - 1$ 求和。作者这里特别利用了几何级数和双重求和交换，把历史梯度那一大串项压缩成一个总和 $S := \sum_k \mathbb{E} \|\nabla f(X_k)\|_F$ 。  MuonNesterov
4. 然后把右边也含 S 的那部分移到左边，于是出现了 ρ 。这就是为什么 $\rho > 0$ 必须成立。  MuonNesterov

文中最后还代入了一组随 horizon 变化的参数：

$$\beta = 1 - \sqrt{1/K}, \quad \eta = \sqrt{1/(dK^{3/4})},$$

并给出一些恒等式，比如

$$\frac{1}{\eta K} = \frac{\sqrt{d}}{K^{1/4}}, \quad \frac{1}{K(1-\beta)} = \frac{1}{K^{1/2}}, \quad (1-\beta)^{(\alpha-1)/\alpha} = K^{-(\alpha-1)/(2\alpha)}.$$

这一步的意思是：只要按合适方式选 β, η ，定理里的各项都会随 K 下降，从而得到明确的收敛速率。

 MuonNesterov

一句话总结：

Theorem B.6 给出了带 Nesterov 动量的 Muon 在 exact polar decomposition、heavy-tailed noise 条件下的主收敛界；它说明平均梯度范数会下降，但前提是 batch 足够大使 $\rho > 0$ ，并且动量、步长、heavy-tail 噪声强度之间要平衡。

顺便提醒一下，这个定理后面 B.1/B.2 小节里又把它转成了更直接的 sample complexity 结论。  MuonNesterov

你要的话，我下一条可以专门讲 “Theorem B.6 里为什么会冒出 ρ ”，这是最关键的一步。

Sources

     ...

B.1 SAMPLE COMPLEXITY讲了什么

Thought for 16s >

B.1 SAMPLE COMPLEXITY 这一小节在做的事很简单：

把 Theorem B.6 的收敛上界，翻译成“为了达到误差 ε ，总共要用多少样本”。  MuonNesterov

它的逻辑分 3 步。

1. 先保证定理里的稳定性条件成立

前面 Theorem B.6 里有个关键量

$$\rho = 1 - \frac{(1 + \sqrt{d})\kappa_\alpha\sigma_1}{B^{(\alpha-1)/\alpha}}.$$

B.1 先选 batch size B 足够大，使 $\rho \geq \frac{1}{2}$ 。文中给的是

$$B \geq \left(2\kappa_\alpha\sigma_1(1 + \sqrt{d})\right)^{\alpha/(\alpha-1)}.$$

这一步的意思是：

batch 要先大到足以压住 heavy-tail 且和梯度耦合的噪声。

不然主下降项会被噪声吃掉，后面的复杂度推导就立不住。  MuonNesterov

2. 再看平均梯度范数的两个主要来源

接着它选步长

$$\eta = \sqrt{1/K},$$

然后把 Theorem B.6 的界简化成

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F \leq O(K^{-1/2}) + O\left(B^{-(\alpha-1)/\alpha}\right).$$

这句话特别重要。它说最终误差主要由两部分组成：

- 迭代步数不够多带来的项： $O(K^{-1/2})$
- batch 不够大带来的 heavy-tail 噪声项： $O(B^{-(\alpha-1)/\alpha})$

也就是说，这里是在平衡两种资源：

- 多跑几步 K
- 每步多采样 B

 MuonNesterov

3. 令这两项都达到 $O(\varepsilon)$

为了让最终平均梯度范数达到 $O(\varepsilon)$ ，就分别让上面两项都不超过 $O(\varepsilon)$ ：

从

$$K^{-1/2} \sim \varepsilon$$

得到

$$K = O(\varepsilon^{-2}).$$

从

$$B^{-(\alpha-1)/\alpha} \sim \varepsilon$$

得到

$$B = O\left(\varepsilon^{-\alpha/(\alpha-1)}\right).$$

于是总样本复杂度就是

$$K \times B = O\left(\varepsilon^{-2-\alpha/(\alpha-1)}\right).$$

把指数通分后应当是

$$O\left(\varepsilon^{-(3\alpha-2)/(\alpha-1)}\right).$$

文中最后也说，当 $\alpha = 2$ 时，这退化成

$$O(\varepsilon^{-4}),$$

并称这是 optimal。  MuonNesterov

直观理解

这一小节的核心意思就是：

在 heavy-tail 噪声下，想把 Muon 训练到精度 ε ，不仅要增加迭代次数 K ，还必须增加 batch B 来平均掉重尾噪声。

而且：

- α 越小，尾巴越重；
- $(\alpha - 1)/\alpha$ 越小，说明 batch 提升带来的收益越慢；
- 所以总样本复杂度会变差。

这正是 heavy-tail 优化和普通有限方差优化最大的区别。  MuonNesterov  MuonNesterov

一句总结

B.1 SAMPLE COMPLEXITY 讲的是：由 Theorem B.6 可知，要达到 ε -精度，需要 $K = O(\varepsilon^{-2})$ 次迭代、每次 batch 大小 $B = O(\varepsilon^{-\alpha/(\alpha-1)})$ ，因此总样本复杂度是 $O(\varepsilon^{-(3\alpha-2)/(\alpha-1)})$ ，在 $\alpha = 2$ 时变成 $O(\varepsilon^{-4})$ 。

 MuonNesterov

顺便说一句，这一小节里“from Theorem B.10”看起来像是笔误，因为它实际位置和内容更像是在接 Theorem B.6 来推。  MuonNesterov  MuonNesterov

Sources

     ...

第8页开始的B.2 PARAMETERS INDEPENDENT OF α 讲了什么

Thought for 4s

第 8 页开始的 B.2 PARAMETERS INDEPENDENT OF α ，核心是在说：

前面 Theorem B.6 得到的平均梯度范数上界里，作者想选一组“随迭代轮数 K 变化”的参数 β, η ，而这组参数本身不需要依赖 α 。也就是“调参不看 α ”，但最后得到的收敛率表达式仍然会通过幂次体现出 α 的影响。

 MuonNesterov

它这小节基本做了三件事。

第一件事，先把前面的主结论再写一遍。

它重新写出

$$\rho := 1 - \frac{(1 + \sqrt{d})\kappa_\alpha \sigma_1}{B^{(\alpha-1)/\alpha}},$$

并给出平均梯度范数的上界：

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F \leq \frac{f(X_0) - f^*}{\eta K \rho} + \frac{Ld}{2\rho} \eta + \frac{1 + \sqrt{d}}{\rho} \left[\frac{\mathbb{E} \|\epsilon_0\|_F}{K(1 - \beta)} + \frac{\beta^2}{1 - \beta} L \eta \sqrt{d} + \frac{\kappa_\alpha \Gamma_\alpha}{B^{(\alpha-1)/\alpha}} \sigma_0 (1 - \beta)^{(\alpha-1)/\alpha} + \frac{\kappa}{B^{(c}} \right]$$

这其实就是把 B.6 的 bound 搬过来，作为这一小节的起点。  MuonNesterov

第二件事，它选了一组 不依赖 α 的 horizon-dependent 参数：

$$\beta = 1 - \sqrt{\frac{1}{K}}, \quad \eta = \sqrt{\frac{1}{dK^{3/4}}}.$$

然后它列出这组参数带来的几个恒等式：

$$\frac{1}{\eta K} = \frac{\sqrt{d}}{K^{1/4}}, \quad \frac{1}{K(1 - \beta)} = \frac{1}{K^{1/2}}, \quad \frac{\eta \sqrt{d}}{1 - \beta} = \frac{1}{K^{1/4}}, \quad (1 - \beta)^{(\alpha-1)/\alpha} = K^{-(\alpha-1)/(2\alpha)}.$$

这里“parameters independent of α ”的意思就是： β 和 η 的选法不需要知道 α 是多少；它们只依赖 K 和 d 。

 MuonNesterov

第三件事，它根据这些代换，直接声称得到 sample complexity

$$O(\varepsilon^{-2\alpha/(\alpha-1)}).$$

作者想表达的意思大概是：在这组统一参数下，主导误差项由 K 和 heavy-tail 项共同决定，最后得到一个关于 ε 和 α 的复杂度公式。也就是说：

- 参数选择本身不依赖 α ；
- 但 最终收敛速度/样本复杂度 仍然依赖 α ，因为 heavy-tail 的强弱本来就由 α 决定。  MuonNesterov

不过这小节有一个值得你注意的地方：它写得很短，而且和前一小节 B.1 在表述上有点不一致。

B.1 刚刚给出的总样本复杂度是

$$K \times B = O(\varepsilon^{-2-\alpha/(\alpha-1)}) = O(\varepsilon^{-(3\alpha-2)/(\alpha-1)}),$$

而 B.2 最后突然写成

$$O(\varepsilon^{-2\alpha/(\alpha-1)}).$$

这两个指数一般并不相同，所以从文稿现有内容看，B.2 更像是在说某个特定设定下的“另一种规模结论”，但推导细节没有在这一页展开清楚。因此如果你在读的时候觉得这里跳步很大，这个感觉是对的。

 MuonNesterov

所以最简洁的总结是：

B.2 讲的是：选一组不依赖 heavy-tail 参数 α 的统一调参方式 (β, η) ，然后把 B.6 的 bound 代进去，说明即便不按 α 专门调参，也能得到一个随 K 衰减的收敛界；只是最终复杂度的幂次仍然会体现 α 的影响。

你要的话，我可以下一条继续帮你做一件更具体的事：

把 B.1 和 B.2 的复杂度公式为什么看起来矛盾，逐项对照出来。

Sources

     ...

lemma B.7讲了什么，一句话

Thought for a second

Lemma B.7 一句话就是：在 f 为 L -smooth 时，Muon 前 K 步的累计梯度范数由“初始函数差 + 累计方向误差 $M_k - \nabla f(X_k)$ + 步长平方项”共同上界，因此只要把方向误差控住，就能得到整体收敛。

 MuonNesterov

Sources

     ...

Lemma B.8讲了什么，一句话

Thought for a second

Lemma B.8 一句话就是：它把 Muon 的误差项 $S_k = M_k - \nabla f(X_k)$ 显式展开成“初始梯度项 + 历史真梯度的几何加权 + 当前及历史噪声的几何加权和”，从而说明 S_k 本质上是由动量记忆下来的梯度与噪声累积构成的。  MuonNesterov

Sources



Lemma B.9讲了什么，一句话

Thought for a second

Lemma B.9 一句话就是：它对 Lemma B.8 里的展开式取期望并做上界，说明 Muon 的误差 S_k 可以由“初始梯度残差 + 历史梯度的几何加权和 + heavy-tail 噪声项”共同控制。 MuonNesterov

Sources



Theorem B.10.讲了什么

Thought for 4s

Theorem B.10 讲的是：

在 exact polar decomposition、 f 满足 smooth、噪声满足 generalized heavy-tail 假设时，只要 batch size B 足够大、动量系数 β 足够小，使得一个稳定性常数 $\rho > 0$ ，那么 Muon with Nesterov momentum 的平均梯度范数

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F$$

会被“初始函数差项 + 步长项 + heavy-tail 噪声项 + 初始梯度残差项”上界住，因此算法能收敛到近似 stationary point。 MuonNesterov

更直白一点，它的核心信息有三层：

1. 先给条件：

需要 B 不能太小、 β 不能太大，这样

$$\rho := 1 - (1 + \sqrt{d}) \left(\beta + \frac{2\sqrt{\pi}C_\alpha\sigma_1}{B^{(\alpha-1)/\alpha}(1-\beta)} \right) > 0.$$

这表示动量累计误差和重尾噪声不能压过主下降项。 MuonNesterov

2. 再给结论：

在这些条件下，

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_F$$

会被几项控制住：

- $\frac{f(X_0)-f^*}{\eta\rho K}$ ：初始化差距
- $\frac{dL\eta}{2\rho}$ ：步长/平滑性代价
- $\frac{4\sqrt{\pi}(1+\sqrt{d})C_\alpha\sigma_0}{\rho(1-\beta^\alpha)^{1/\alpha}B^{(\alpha-1)/\alpha}}$ ：heavy-tail 底噪
- $\frac{(1+\sqrt{d})\|\nabla f(X_0)\|_F}{\rho(1-\beta)K}$ ：初始化梯度残差

所以平均梯度会随 K 增大、 B 增大而变小。 MuonNesterov

3. 它在整段证明链里的作用：

- Lemma B.7：把累计下降和累计误差 $S_k = M_k - \nabla f(X_k)$ 连起来。 MuonNesterov

- Lemma B.8: 把 S_k 展开成历史梯度和历史噪声的加权和。  MuonNesterov
- Lemma B.9: 给 S_k 做期望上界。  MuonNesterov
- Theorem B.10: 把这些全合起来, 得到最终主收敛界。  MuonNesterov

一句话压缩就是:

Theorem B.10 证明了: 只要 batch 够大、动量别太强, 带 Nesterov 动量的 Muon 在 heavy-tailed 噪声下仍然有平均梯度收敛保证。  MuonNesterov

要的话, 我可以下一条继续把 Theorem B.10 里的 ρ 为什么长成这样 单独讲清楚。

Sources

     ...

Remark B.11.讲了啥

Thought for a couple of seconds

Remark B.11 讲的是:

如果噪声里不含“与梯度大小耦合”的那部分, 也就是 $\sigma_1 = 0$, 那么 Muon 的收敛条件会明显放宽: 不再需要对 batch size B 施加下界, 只要把动量 β 选得足够小 (文中给的是 $\beta < 1/(2 + \sqrt{d})$), 就仍能保证稳定性常数 $\rho > 0$, 从而得到和 Theorem B.10 类似的平均梯度收敛界。  MuonNesterov

更白话一点:

- Theorem B.10 里最麻烦的是 σ_1 这一项, 因为它表示噪声会随着 $\|\nabla f(X_k)\|$ 变大而变大, 所以必须要求 batch 足够大 来压住它。  MuonNesterov
- Remark B.11 说, 如果现在 $\sigma_1 = 0$, 也就是噪声只有“固定底噪” σ_0 , 没有那种梯度相关的放大效应, 那么

$$\rho = 1 - (1 + \sqrt{d}) \frac{\beta}{1 - \beta}$$

只跟 β 有关了。于是只要选 $\beta < 1/(2 + \sqrt{d})$, 就能让 $\rho > 0$ 。  MuonNesterov

所以一句话总结就是:

Remark B.11 的意思是: 在更容易的噪声情形 $\sigma_1 = 0$ 下, 理论条件更宽松, Muon 不需要大 batch 也能成立收敛保证, 主要只需控制动量别太大。  MuonNesterov

Sources

     ...

B.4 SAMPLE COMPLEXITY和B.5 PARAMETERS INDEPENDENT OF α 讲了啥, 和之前的有啥区别

Thought for 12s >

这两小节本质上是在把 Theorem B.10 的主收敛界, 继续翻译成更具体的“复杂度/调参”结论。和前面的 B.1 / B.2 相比, 最大的区别是: B.1 / B.2 是接着前面那套较早的 B.3–B.6 证明链; B.4 / B.5 是接着后面更新后的 B.7–B.10 证明链。 所以它们讨论的是同一个主题, 但对应的是另一套更系统的主定理。  MuonNesterov

 MuonNesterov

先说 B.4 SAMPLE COMPLEXITY。

它讲的是：在 Theorem B.10 的条件下，为了让平均梯度范数达到 $O(\varepsilon)$ ，应该怎么选 batch 和迭代轮数。它先要求

$$B \geq (16\sqrt{\pi}C_\alpha\sigma_1(1+\sqrt{d}))^{\alpha/(\alpha-1)}, \quad \beta \leq \frac{1}{8+4\sqrt{d}},$$

这样可以保证 $\rho \geq 1/2$ 。然后选步长

$$\eta = \sqrt{1/K},$$

于是平均梯度范数上界变成若干项之和：两项是 $1/\sqrt{K}$ 级别，另一个 heavy-tail 噪声项是 $B^{-(\alpha-1)/\alpha}$ 级别，还有一个初始化梯度残差项是 $1/K$ 级别。于是令

$$K = O(\varepsilon^{-2}), \quad B = O(\varepsilon^{-\alpha/(\alpha-1)}),$$

就得到总样本复杂度

$$K \times B = O(\varepsilon^{-2-\alpha/(\alpha-1)}) = O(\varepsilon^{-(3\alpha-2)/(\alpha-1)}).$$

并且当 $\alpha = 2$ 时退化成 $O(\varepsilon^{-4})$ 。所以 B.4 的结论和 B.1 在复杂度阶数上其实是一样的，只是它现在是从 Theorem B.10 那条新证明链重新推出一次，而且条件写得更明确。  MuonNesterov

再说 B.5 PARAMETERS INDEPENDENT OF α 。

这一节讨论的是一个更特殊、更容易的情形： $\sigma_1 = 0$ 。也就是噪声里没有“和梯度大小耦合”的那部分，只有固定底噪 σ_0 。在这种情况下，文中说可以取

$$\beta < \frac{1}{4+2\sqrt{d}}, \quad \rho = 1 - (1+\sqrt{d})\frac{\beta}{1-\beta} > \frac{1}{2},$$

并得到一个不再含 σ_1 的平均梯度上界；接着它进一步取 batch size $B = 1$ ，于是噪声项里也不再需要靠增大 batch 来压制。换句话说，这一节的重点是：

当 $\sigma_1 = 0$ 时，不需要大 batch，甚至单样本 $B = 1$ 也能成立理论。

这和 B.4 最大不同，因为 B.4 里为了压住梯度相关 heavy-tail 噪声，必须把 B 取得足够大。  MuonNesterov

和前面的 B.1 / B.2 对比，可以这样看：

- B.1：从前一套定理出发，得到一般 heavy-tail 情况下的 sample complexity，结论是

$$K = O(\varepsilon^{-2}), \quad B = O(\varepsilon^{-\alpha/(\alpha-1)}), \quad KB = O(\varepsilon^{-(3\alpha-2)/(\alpha-1)}).$$

 MuonNesterov

- B.2：想说明可以选一组不显式依赖 α 的 β, η ，但它写得比较跳，最后直接报了一个复杂度式。

 MuonNesterov

- B.4：和 B.1 做的是同类事情，但现在是基于 Theorem B.10 这条更新后的分析路线重新推，条件更明确，尤其明确要求 B 大、 β 小。复杂度阶数本质上和 B.1 一致。  MuonNesterov
- B.5：不是一般情形，而是专门讨论 $\sigma_1 = 0$ 的简化版；它最大的特点不是“复杂度指数变成什么”，而是“不需要靠大 batch 压噪声了”，所以可以直接看 $B = 1$ 的情况。  MuonNesterov

还有一个你读的时候会感觉到的区别：B.5 这一页在当前文件里是截断的。文字到 “Now, we choose $\beta = 1 -$ ” 就停了，所以它最后原本想继续给出怎样的具体参数代入或最终复杂度，在这份可见文本里并没有完整展示出来。我不想瞎补这部分。  MuonNesterov

一句话总结：

B.4 是“新版主定理下的一般 heavy-tail 样本复杂度”，本质上复现了 B.1 的结论；B.5 是“新版主定理下、且 $\sigma_1 = 0$ 时的特例”，强调这时连大 batch 都不再需要。

要的话，我可以下一条直接帮你画一个 B.1/B.2 和 B.4/B.5 的对照表。

Sources

B.4 SAMPLE COMPLEXITY和B.5 PARAMETERS INDEPENDENT OF α 讲了啥一句话

Thought for a second

一句话讲，B.4 SAMPLE COMPLEXITY 讲的是：在一般 heavy-tail 情况下，为了把平均梯度范数压到 $O(\varepsilon)$ ，需要取 $K = O(\varepsilon^{-2})$ 、 $B = O(\varepsilon^{-\alpha/(\alpha-1)})$ ，所以总样本复杂度是 $O(\varepsilon^{-(3\alpha-2)/(\alpha-1)})$ ；而 B.5 PARAMETERS INDEPENDENT OF α 讲的是：在更特殊的 $\sigma_1 = 0$ 情形下，收敛条件显著放宽，甚至可取 $B = 1$ ，也就是不再需要靠大 batch 来压住噪声。  MuonNesterov

Sources

     ...

Theorem C.1.讲了啥

Thought for 4s

Theorem C.1 讲的是：

当 Muon 用的不是精确 polar 因子 $O(M_k)$ ，而是一个近似的 $T(M_k)$ 时，只要近似误差 Δ_k 可控，那么单步更新仍然有“下降不等式”；只是原本的主下降项会被削弱成 $(1 - \Delta_k)\|M_k\|_*$ ，而误差放大项会变成 $(\sqrt{d} + \Delta_k)\|\nabla f(X_k) - M_k\|_*$ 。文中写成

$$f(X_{k+1}) \leq f(X_k) - \eta\|M_k\|_*(1 - \Delta_k) + \eta\|\nabla f(X_k) - M_k\|_*(\sqrt{d} + \Delta_k) + \frac{\eta^2 L}{2}(\sqrt{d} + \Delta_k)^2.$$

 MuonNesterov

直白说，它表达的是三件事：

1. 近似 polar 不会立刻毁掉下降性，算法 still 有单步下降保证。  MuonNesterov
2. 但下降幅度会变差：理想情况下是按 $\|M_k\|_*$ 下降，现在被乘了个 $1 - \Delta_k$ 。 Δ_k 越大，主下降越弱。
 MuonNesterov
3. 方向误差也会被放大：原来和 $\sqrt{d}$ 有关，现在变成 $\sqrt{d} + \Delta_k$ ，说明近似误差越大，更新方向偏离真梯度时的代价越大。  MuonNesterov

一句话总结：

Theorem C.1 就是在给“inexact polar decomposition 的单步下降公式”，说明近似 polar 仍可收敛分析，但会用 Δ_k 同时削弱主下降项、放大误差项。  MuonNesterov

要的话，我可以下一条继续讲 Theorem C.2 和 C.1 的关系。

Sources

     ...

Theorem C.2.讲了啥，Theorem C.2 和 C.1 的关系

Thought for a couple of seconds

Theorem C.2 讲的是：

如果每一步的 polar 近似误差都满足 $\Delta_k \leq \Delta < 1$ ，那么把 Theorem C.1 的单步下降不等式从 $k = 0$ 累加到 $K - 1$ 后，可以得到一个“累计梯度范数上界”：

$$\eta(1 - \Delta) \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|_* \leq f(X_0) - f^* + \eta(1 + \sqrt{d}) \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k) - M_k\|_* + \frac{\eta^2 L K}{2} (\sqrt{d} + \Delta)^2.$$

意思是：即使用的是近似 polar 分解，只要误差一直小于 1，Muon 的累计梯度仍然能被“初始函数差 + 方向误差累计 + 平滑性项”控制住。  MuonNesterov

Theorem C.2 和 C.1 的关系很直接：

- C.1 是单步版：分析一次更新后，函数值怎么变。  MuonNesterov
- C.2 是累计版：把 C.1 对所有步求和，再用 $\Delta_k \leq \Delta$ 统一替换，得到整个训练过程的总上界。
 MuonNesterov

再压成一句话：

C.1 证明“每一步还能下降”，C.2 证明“把这些步加起来后，整体仍然收敛可控”。  MuonNesterov

Sources

     ...

Lemma C.3.讲了啥

Thought for a few seconds

Lemma C.3 讲的是：

在有界方差假设下，Muon 的方向误差

$$S_k := M_k - \nabla f(X_k)$$

其累计平方核范数

$$\sum_{k=0}^{K-1} \mathbb{E} \|S_k\|_*^2$$

可以被三类东西控制住：初始动量状态 C_0 、整个过程里的梯度平方和、以及噪声方差 σ^2 。文中给出的结论是

$$\sum_{k=0}^{K-1} \mathbb{E} \|S_k\|_*^2 \leq \frac{2\beta^2}{1-\lambda} \mathbb{E} \|C_0\|_*^2 + \frac{4\beta^2(1+1/\varepsilon)}{1-\lambda} \sum_{j=0}^{K-1} \mathbb{E} \|\nabla f(X_j)\|_*^2 + \frac{4\beta^2(1+1/\varepsilon)}{1-\lambda} K d \sigma^2 + 2K d \sigma^2,$$

其中 $\lambda = (1 + \varepsilon)\beta^2 < 1$ 。  MuonNesterov

直白说，它的意思是：

只要 β 不太大，使得 $(1 + \varepsilon)\beta^2 < 1$ ，那么动量带来的误差 S_k 不会无控制地爆炸；它的总量可以被初值、真实梯度大小、和噪声强度统一上界。这一步的作用是给后面的 Theorem C.4 提供对误差项 $\sum_k \mathbb{E} \|S_k\|_*^2$ 的控制。  MuonNesterov

一句话总结：

Lemma C.3 证明了：在 finite-variance 情况下，近似 polar 场景里 Muon 的累计方向误差平方是可控的，前提是动量 β 足够小。  MuonNesterov

Sources

     ...

Thought for a couple of seconds

Theorem C.4 讲的是：

在 inexact polar decomposition、有限方差噪声下，只要动量 β 选得足够小，使某个稳定性常数 $\rho > 0$ ，那么 Muon 在前 K 步里至少有一步的期望梯度范数会很小；也就是说，它能收敛到一个近似 stationary point。文中给出的结论是

$$\min_{0 \leq k \leq K-1} \mathbb{E} \|\nabla f(X_k)\|_* \leq \frac{f(X_0) - f^*}{\eta \rho K} + \frac{2\beta^2(1 + \sqrt{d})}{(1 - \lambda)\rho K} \mathbb{E} \|C_0\|_*^2 + \frac{\eta L}{2\rho} (\sqrt{d} + \Delta)^2 + \frac{2(1 + \sqrt{d})d\sigma^2}{\rho} \left(1 + \frac{2\beta^2(1 + 1/\varepsilon)}{1 - \lambda}\right),$$

其中

$$\rho = (1 - \Delta) - (1 + \sqrt{d}) \frac{4\beta^2(1 + 1/\varepsilon)}{1 - \lambda} > 0, \quad \lambda = (1 + \varepsilon)\beta^2.$$

📄 MuonNesterov

直白说，这个定理在表达四件事。

第一，它是 C 部分的主收敛结论。

前面的 Theorem C.2 说，累计梯度范数受误差项 $\sum_k \|\nabla f(X_k) - M_k\|_*$ 控制；Lemma C.3 又把这个误差项的平方和控制住了。Theorem C.4 就是把这两步拼起来，得到最终的“最小梯度范数”上界。 📄 MuonNesterov

📄 MuonNesterov

📄 MuonNesterov

第二，近似 polar 的误差 Δ 会直接削弱收敛性。

式子里有 $(\sqrt{d} + \Delta)^2$ 和 $(1 - \Delta)$ ； Δ 越大，平滑性代价越大，可用来保证下降的“净空间”越小。所以近似 polar 不是白来的，它会让常数变差。 📄 MuonNesterov 📄 MuonNesterov

第三，动量 β 不能太大。

因为稳定性常数

$$\rho = (1 - \Delta) - (1 + \sqrt{d}) \frac{4\beta^2(1 + 1/\varepsilon)}{1 - \lambda}$$

必须大于 0。也就是说，如果 β 太大，动量累计误差会把主下降项吃掉，理论保证就失效。 📄 MuonNesterov

第四，结论是“存在某一步足够平”，不是每一步都小。

它控制的是

$$\min_{0 \leq k \leq K-1} \mathbb{E} \|\nabla f(X_k)\|_*,$$

所以属于随机非凸优化里很常见的 stationarity 结论：跑了 K 步之后，至少能找到一个梯度不大的迭代点。

📄 MuonNesterov

一句话总结：

Theorem C.4 证明了：即使 Muon 用的是近似 polar decomposition，只要近似误差 Δ 和动量 β 都控制得住，它仍然能保证找到一个近似驻点；代价是收敛常数会被 Δ 、 β 、维度 d 和噪声方差 σ^2 一起拖慢。

📄 MuonNesterov

Sources

📄 🍌 📄 📄 🔄 ...

Thought for a couple of seconds

Lemma C.6 讲的是：

在 α -moment heavy-tail 噪声下，Muon 的方向误差

$$S_k := M_k - \nabla f(X_k)$$

其累计的 α 次核范数

$$\sum_{k=0}^{K-1} \mathbb{E} \|S_k\|_*^\alpha$$

可以被三类量控制住：初始动量状态 C_0 、整个过程里的梯度 α 次和、以及噪声强度 $d^{\alpha/2} \sigma^\alpha$ 。文中具体给出

$$\sum_{k=0}^{K-1} \mathbb{E} \|S_k\|_*^\alpha \leq \frac{(1+\varepsilon)\beta^\alpha}{1-\lambda} \mathbb{E} \|C_0\|_*^\alpha + \frac{(1+\varepsilon)^2 \beta^\alpha C(\varepsilon)}{1-\lambda} \sum_{j=0}^{K-1} \mathbb{E} \|\nabla f(X_j)\|_*^\alpha + \left(\frac{(1+\varepsilon)\beta^\alpha C(\varepsilon)^2}{1-\lambda} + C(\varepsilon) \right) K d^{\alpha/2} \sigma^\alpha,$$

其中 $\lambda = (1+\varepsilon)\beta^\alpha < 1$, $C(\varepsilon) = 16(1+1/\varepsilon)$ 。  MuonNesterov

直白说，它是在做 Lemma C.3 的 heavy-tail 版本：

- C.3 控的是二阶情形下的 $\sum \mathbb{E} \|S_k\|_*^2$ ；  MuonNesterov
- C.6 改成只假设 $\alpha \in (1, 2]$ 阶矩有界，于是控制的是 $\sum \mathbb{E} \|S_k\|_*^\alpha$ 。  MuonNesterov

它的核心意思就是：

即便噪声只有 heavy-tail 的 α -moment 控制，Muon 的累计方向误差仍然不会失控；只要 β 够小，使 $(1+\varepsilon)\beta^\alpha < 1$ ，这个误差总量仍能被初值、真实梯度大小和噪声强度统一上界。  MuonNesterov

顺便说，Lemma C.6 里反复用到 Lemma C.5 的统一 Young 不等式，把

$$\|A + B\|^\alpha$$

拆成“主项 + 噪声项”，这样才能在 $\alpha < 2$ 时继续做递推。  MuonNesterov  MuonNesterov

一句话总结：

Lemma C.6 证明了：在 heavy-tail 噪声下，近似 polar 场景里 Muon 的累计方向误差 α -矩是可控的，这为后续做 heavy-tail 收敛分析提供了误差上界。

Sources

     ...

previous analysis 讲了啥，Lemma D.1. 讲了啥

Thought for a couple of seconds

Previous Analysis 这一节讲的是：作者先回顾一套**更早、更粗的分析思路**，用来说明以前是怎么分析 Muon 的，以及这套思路主要把误差拆成哪几块。它的主线不是直接研究平均梯度范数，而是先研究

$$\|X_{k+1} - X^*\|_F^2$$

怎么递推，然后把

$$\|T(M_k) - G_k\|_F^2$$

拆成三类来源：

1. 近似 polar 分解误差： $T(M_k) - O(M_k)$

- 2. polar 操作本身带来的变化: $O(M_k) - M_k$
- 3. Nesterov 动量带来的漂移: $M_k - G_k$

所以这一节本质上是在搭一个“旧版误差分解框架”。 MuonNesterov

Lemma D.1 讲的是: 在 f 满足 smooth、strongly convex, 随机梯度满足有界方差时, Muon 一步更新后到最优点的平方距离满足一个上界:

$$\mathbb{E}[\|X_{k+1} - X^*\|_F^2 \mid X_k]$$

可以被“上一时刻距离项”减去一部分“函数值下降项”, 再加上两类误差项控制住:
一类是 $\|T(M_k) - G_k\|_F^2$, 表示实际更新方向和随机梯度之间的差距; 另一类是噪声方差项 $2\eta^2\sigma^2$ 。也就是说, 这个引理的核心结论是:

只要能把 $T(M_k)$ 和 G_k 的偏差控制住, 算法到最优点的距离就会递减。 MuonNesterov

一句话压缩:

- Previous Analysis: 回顾一套旧的、按“距离到最优 + 三种误差来源”来分析 Muon 的方法。 MuonNesterov
- Lemma D.1: 给出这套旧方法的基础一步递推式, 说明“距离缩小多少”取决于函数下降和更新方向误差 $T(M_k) - G_k$ 有多大。 MuonNesterov

如果你愿意, 我下一条可以把 为什么作者说这套 previous analysis 比 B/C 部分的新分析更粗 也顺手讲清楚。

Sources

📄 📄 📄 📄 📄 ...

所以这个paper的结论都是什么

Thought for 5s

可以把这篇 paper 的结论概括成 6 点:

- 1. 它想证明: 带 Nesterov 动量的 Muon 是可分析、可收敛的。
文章的核心对象是

$$C_k = \beta C_{k-1} + G_k, \quad M_k = \beta C_k + G_k, \quad X_{k+1} = X_k - \eta T(M_k),$$

也就是“动量 + polar 方向更新”的 Muon 变体。整篇的主线就是给这个更新规则建立理论收敛保证。 MuonNesterov

- 2. 在 exact polar decomposition 下, 即使噪声是 heavy-tailed, 也能得到平均梯度收敛界。
B 部分证明了: 如果随机梯度噪声只满足 $\alpha \in (1, 2]$ 阶矩有界, 而不要求有限方差, 那么 Muon 仍然可以得到

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(X_k)\|$$

这样的上界; 但前提是 batch 要足够大、动量不能太激进, 从而让一个稳定性常数 $\rho > 0$ 。也就是说, 这篇 paper 的一个核心结论是: Muon 不只在“干净噪声”下可分析, 在 heavy-tail 噪声下也能分析。 MuonNesterov

- 3. heavy-tail 情况下, batch size 是关键。
文中反复出现

$$B^{-(\alpha-1)/\alpha}$$

这样的项, 说明 batch 越大, heavy-tail 噪声影响越小; 而且如果噪声里有和梯度大小耦合的部分 ($\sigma_1 > 0$), 那 batch 还必须大到一定程度, 才能保证主下降项不被噪声吃掉。换句话说, paper 的理论结论之一是:

Muon 在重尾噪声下能收敛，但要靠足够大的 batch 稳住。

[MuonNesterov](#)

[MuonNesterov](#)

4. 它给出了样本复杂度结论。

在一般 heavy-tail 情况下，文中给出的结论是：要把平均梯度范数压到 $O(\varepsilon)$ ，可以取

$$K = O(\varepsilon^{-2}), \quad B = O\left(\varepsilon^{-\alpha/(\alpha-1)}\right),$$

于是总样本复杂度

$$K \times B = O\left(\varepsilon^{-(3\alpha-2)/(\alpha-1)}\right),$$

当 $\alpha = 2$ 时退化成 $O(\varepsilon^{-4})$ 。这就是 paper 对“训练成本”给出的主要定量结论。

[MuonNesterov](#)

[MuonNesterov](#)

5. 即便 polar decomposition 不是精确的，只要近似误差小，也还能收敛。

C 部分的核心结论是：把精确 polar $O(M_k)$ 换成近似的 $T(M_k)$ 后，单步下降仍成立，只是主下降项会被 $(1 - \Delta_k)$ 削弱，误差项会被 $(\sqrt{d} + \Delta_k)$ 放大；进一步地，只要 $\Delta_k \leq \Delta < 1$ 且动量不太大，就还能得到累计梯度或最小梯度范数的收敛结论。也就是说，Muon 对 inexact polar decomposition 有一定鲁棒性，但误差 Δ 会直接拖慢收敛常数。

[MuonNesterov](#)

[MuonNesterov](#)

6. 如果噪声不和梯度耦合，理论条件会明显放宽。

Remark B.11 和 B.5 讨论了 $\sigma_1 = 0$ 的情形：这时不再需要靠大 batch 去压“梯度相关噪声”，理论条件只需控制动量 β 不太大，甚至可以直接考虑 $B = 1$ 。所以 paper 的另一个 takeaway 是：最难的不是重尾本身，而是“噪声大小还跟梯度一起变大”这件事。

[MuonNesterov](#)

[MuonNesterov](#)

如果把整篇 paper 压成一句总论，就是：

这篇 paper 的主要结论是：带 Nesterov 动量的 Muon，在 exact 或 mildly inexact 的 polar decomposition 下，都能建立收敛理论；在 heavy-tailed 噪声下也可以分析，但需要通过 batch size、动量系数和近似误差精度来平衡稳定性与收敛速度。

[MuonNesterov](#)

[MuonNesterov](#)

[MuonNesterov](#)

再补一句更“读后感”式的总结：

这篇文稿的真正贡献不是提出了一个全新算法，而是试图说明：Muon 这种“动量 + polar 方向”的更新，在更现实的噪声模型和近似数值实现下，理论上仍然站得住。

[MuonNesterov](#)

[MuonNesterov](#)

要的话，我可以下一条把这些结论整理成一页“答辩版总结”，只保留最重要的 3 个贡献和 2 个限制。

Sources

[📄](#) [👍](#) [💬](#) [📌](#) [🔄](#) [⋮](#)

这个heavy-tail是指gradient hveavy tail还是data heavy tail

Thought for 5s

这里的 heavy-tail 主要指 stochastic gradient / gradient noise 是 heavy-tailed，不是 paper 直接在建模 “data heavy-tail”。

[MuonNesterov](#)

更准确地说，Assumption B.1 写的是每个 G_k^i 都是 $\nabla f(X_k)$ 的无偏估计，并且它的偏差

$$G_k^i - \nabla f(X_k)$$

只要求满足 $\alpha \in (1, 2]$ 阶矩有界：

$$\mathbb{E}[\|G_k^i - \nabla f(X_k)\|_F^\alpha \mid X_k] \leq \sigma_0^\alpha + \sigma_1^\alpha \|\nabla f(X_k)\|_F^\alpha.$$

所以 heavy-tail 说的是 梯度估计误差/随机梯度噪声的尾部很重；当 $\alpha < 2$ 时，甚至允许方差都不一定有 限。

[MuonNesterov](#)

如果再说白一点：

- paper 里直接假设的是 gradient noise heavy-tail;
- 不是直接假设 data distribution heavy-tail。

当然，现实里 data heavy-tail 可能会导致 per-sample gradient heavy-tail，但这是更上游的成因；这篇 paper 没有直接分析数据分布的尾部，而是直接从随机梯度 G_k^i 的重尾性质开始建模。  MuonNesterov

一句话：

它讲的是 gradient / stochastic gradient heavy-tail，不是 data heavy-tail；data heavy-tail 最多是一个可能来源，但不是文中显式建模对象。

Sources

     ...

gradient / stochastic gradient heavy-tail具体是啥意思，由什么导致的，有没有什么例子'

Thought for 18s >

具体意思是：

gradient / stochastic gradient heavy-tail 指的是“梯度随机变量有不小概率出现特别大的值”，也就是它的尾部比高斯型、次高斯型更重。

在你这篇 paper 里，更准确说的是 stochastic gradient noise heavy-tail：作者假设单样本梯度估计 G_k^i 相对真梯度 $\nabla f(X_k)$ 的误差

$$G_k^i - \nabla f(X_k)$$

只有 $\alpha \in (1, 2]$ 阶矩有界，而不要求二阶矩一定有界；这就是它说的 heavy-tailed noises。  MuonNesterov

可以分三层理解。

1. 它“具体是啥意思”

平常有限方差设定里，你会假设

$$\mathbb{E}\|G - \nabla f\|^2 < \infty.$$

这意味着虽然有噪声，但极端大的梯度不常见。

heavy-tail 则是说：

- 大多数样本梯度可能不大，
- 但偶尔会冒出特别大的梯度，
- 而且这种“大离群值”出现的概率，下降得没那么快。

所以 heavy-tail 不是“平均梯度大”，而是“尾部很肥，极端值更常见”。

一个常见的数学刻画是：

- 只知道 α -moment 有界， $\alpha \in (1, 2]$
- 当 $\alpha < 2$ 时，甚至可能 方差都不存在

这就是为什么 paper 里把它和普通 bounded variance 分开写。A.3 是有限方差，B.1 是 heavy-tail。

 MuonNesterov

 MuonNesterov

2. “gradient heavy-tail”和“stochastic gradient heavy-tail”有啥区别

严格说，训练里更常说的是 stochastic gradient heavy-tail。

因为全梯度

$$\nabla f(X) = \frac{1}{n} \sum_{i=1}^n \nabla \ell_i(X)$$

本身是个确定量，不是随机变量。

真正随机的是：

- 单样本梯度 $\nabla \ell_i(X)$
- mini-batch 梯度
- 或者梯度误差 $G - \nabla f$

所以大家口头上说 “gradient is heavy-tailed”，通常其实指：

“按数据抽样后得到的 per-sample gradient / mini-batch gradient 的分布是 heavy-tailed。”

你这篇 paper 用的就是这个意思，而且更精确：它直接假设的是 **梯度估计误差** heavy-tailed。  MuonNesterov

3. 它通常由什么导致

常见原因就是：**有少量样本会贡献异常大的梯度。**

最常见的来源有这些：

(a) 特征本身有长尾或离群值

如果输入 x 的范数偶尔特别大，那梯度也会跟着大。

(b) 残差偶尔特别大

比如回归里某些样本预测得特别离谱，误差巨大，梯度直接被放大。

(c) 稀有但很“难”的样本

例如极少数罕见类别、脏标签、异常文本、超长序列，它们可能让某一步梯度特别大。

(d) 数据分布混合得很杂

多域数据、严重类别不平衡、少量极端子群，都会让 per-example gradient 呈现长尾。

(e) 强噪声目标

比如 RL 里 policy gradient 乘上 return；如果 return 本身重尾，梯度常常也重尾。

(f) reweighting / importance sampling / inverse propensity weighting

权重大时，少量样本会被放大，梯度很容易重尾。

所以，data heavy-tail 可以是原因之一，但 paper 直接建模的是 gradient noise heavy-tail。

具体例子

例子 1：线性回归里有极端样本

损失

$$\ell_i(w) = \frac{1}{2} (x_i^\top w - y_i)^2$$

单样本梯度是

$$\nabla \ell_i(w) = (x_i^\top w - y_i) x_i.$$

如果：

- x_i 偶尔特别大，或者
- y_i 偶尔特别离谱，

那这个梯度就会突然非常大。

所以哪怕大多数样本都正常，只要有少量极端点，单样本梯度分布就会很长尾。

例子 2：分类里 feature norm 长尾

交叉熵分类里，单样本梯度通常和“预测误差 × 特征向量”差不多同量级。

如果少数样本的特征范数很大，或者是极难样本，那么它们的梯度会远大于普通样本。

例子 3：语言模型里的稀有上下文

大部分 token/sequence 很普通，但极少数：

- 很长，
- 很稀有，
- 很难预测，
- 或者质量异常，

会让 loss 和梯度突然变大。这样 batch 梯度有时会被一两个样本主导。

例子 4：强化学习

policy gradient 常见形式是

$$g = \nabla \log \pi(a|s) \cdot R.$$

如果 return R 偶尔特别大，那么梯度也会偶尔特别大。
这就是 RL 中 heavy-tail/high-variance 很常见的原因之一。

它和普通“高方差”有什么区别

不是一回事。

- **高方差**：波动大，但二阶矩还存在。
- **heavy-tail**：不仅波动大，而且极端值更常见；严重时连二阶矩都可能不存在。

所以 heavy-tail 比“只是 noisy”更难处理。

对优化有什么影响

这也是 paper 为什么要单独分析它的原因。

heavy-tail 下会出现这些现象：

- mini-batch 平均虽然还能降噪，但**降得比普通有限方差更慢**
- 偶发的大梯度会让训练很不稳定
- 动量会把这些大噪声“记住”，问题更麻烦
- 理论上常要用更大的 batch、梯度裁剪、鲁棒估计等方法

你这篇 paper 里正是在说明：即使随机梯度噪声是 heavy-tailed，Muon 仍然能分析，但 batch 和动量要配合好。

 MuonNesterov

 MuonNesterov

一句话总结：

stochastic gradient heavy-tail 就是“抽到的大多数样本梯度正常，但少数样本会产生异常大的梯度，而且这种极端值并不罕见”；它常由离群样本、长尾特征、超大残差、稀有难样本、RL 回报重尾等导致。

你要的话，我下一条可以继续讲：为什么 heavy-tail 下 batch averaging 只会出现 $B^{-(\alpha-1)/\alpha}$ 这种缩放，而不是普通的 $1/\sqrt{B}$ 。

Sources

     ...

这个paper主要是story line是什么

Thought for a couple of seconds

这篇 paper 的 story line 可以概括成：

作者想讲的是：Muon 加上 Nesterov momentum 以后，在更现实的两种非理想条件下——一是 stochastic gradient 是 heavy-tailed 的，二是 polar decomposition 只能近似算——依然能给出理论收敛保证。

 MuonNesterov  MuonNesterov  MuonNesterov

如果按章节顺下来，它的叙事线是这样的：

先在 **A 部分**把主角摆出来：研究对象是带 Nesterov 动量的 Muon，

$$C_k = \beta C_{k-1} + G_k, \quad M_k = \beta C_k + G_k, \quad X_{k+1} = X_k - \eta T(M_k),$$

并列出 smooth、strong convex、无偏梯度、有限方差/ α -moment、以及 polar 近似误差这些假设。也就是说，作者先把问题设成“**Muon 的真实训练过程到底能不能分析**”。  MuonNesterov

然后 **B 部分**是第一条主线：先假设 polar decomposition 是精确的，专心处理 **heavy-tailed stochastic gradient noise**。这里作者先说明 batch 平均后噪声怎么随 B 缩小，再建立一个下降不等式，把“累计梯度范数”跟“Muon 方向和真梯度之间的误差”联系起来；接着把这个误差拆成三部分：初始误差、梯度漂移、历史噪声累积；最后把这些误差界代回去，得到平均梯度范数的收敛界和 sample complexity。也就是：**先证明 exact polar + heavy-tail 时，Muon 仍然能收敛**。  MuonNesterov  MuonNesterov  MuonNesterov

接着 **C 部分**是第二条主线：把 exact polar 放松成 **inexact polar decomposition**。这里作者先证明：如果实际用的是近似 $T(M_k)$ ，那单步下降仍然成立，只是主下降项会被 $(1 - \Delta_k)$ 削弱，误差项会被 $(\sqrt{d} + \Delta_k)$ 放大；再把单步结果累积起来，得到整体的梯度控制；最后在有限方差和 heavy-tail 两种噪声设定下，分别控制 $S_k = M_k - \nabla f(X_k)$ 的累计误差，从而给出 inexact polar 下的收敛结论。也就是：**再证明就算 polar 只能近似算，理论也还能站住**。  MuonNesterov

最后 **D 部分**像是一个对照组。作者回顾以前一套更老的分析：从 $\|X_{k+1} - X^*\|^2$ 的递推入手，把误差拆成“近似 polar 误差 + polar 本身的变化 + 动量漂移”。放在全文里，它的作用更像是在暗示：**旧分析太粗，所以前面 B/C 部分才需要一套更贴着 Muon 机制的新分析**。  MuonNesterov

所以把整篇压成一句更像论文摘要的话：

这篇 paper 的故事不是“我发明了 Muon”，而是“我证明了带 Nesterov 动量的 Muon，在重尾梯度噪声和近似 polar 分解这两种现实因素下，依然有可控的误差传播和收敛保证”。  MuonNesterov  MuonNesterov  MuonNesterov

再压缩成最短版本，就是三步：

先定义 Muon + Nesterov，
再证明 exact polar + heavy-tail 可收敛，
再证明 inexact polar 下也基本还能收敛。  MuonNesterov  MuonNesterov  MuonNesterov

我也可以把它整理成一个“introduction/related work/contribution”的答辩式 5 句版本。

Sources

     ...

什么是polar decomposition，跟MUON原本的newton shulz有啥区别，
inexact polar decomposition是什么

Thought for 16s >

可以这样理解：

polar decomposition（极分解） 是一个矩阵分解：把一个矩阵 M 写成

$$M = UH$$

其中 U 是“正交部分”（更准确地说是 orthogonal / unitary factor）， H 是对称半正定部分。
如果对 M 做 SVD，

$$M = U\Sigma V^\top,$$

那么它的 polar 因子就是

$$O(M) = UV^\top.$$

这个 $O(M)$ 保留了“方向/子空间结构”，但把奇异值信息拿掉了。你这篇 paper 里，Muon 的更新方向本质上就是朝这个 polar 因子走：在 A 部分先写成

$$X_{k+1} = X_k - \eta T(M_k),$$

其中 $T(M_k)$ 是对 polar decomposition 的估计；而在 exact polar 的分析里，直接写成 $O(M_k)$ 。

 MuonNesterov  MuonNesterov

它和 Muon 原本的 Newton–Schulz 的区别 是：

- polar decomposition / polar factor 是你想得到的数学对象，也就是“目标方向”；
- Newton–Schulz 是一个数值迭代算法，用来近似算出这个 polar factor。

也就是说，二者不是同层级概念。

polar decomposition 是“要算什么”，

Newton–Schulz 是“怎么去算”。

这篇 paper 其实把这个区分写得很清楚：它一方面把 $O(M_k)$ 当成“true polar decomposition”，另一方面说实际计算里会用 Newton-Schulz 或 Polar Express，因此只能得到一个近似的 $T(M_k)$ ，并假设二者之间有误差。 MuonNesterov  MuonNesterov

所以你问“跟 Muon 原本的 Newton-Schulz 有啥区别”，最短答案就是：

Muon 原本不是在和 polar decomposition 对立，而是在用 Newton–Schulz 去近似 polar decomposition。

再说 inexact polar decomposition 是什么。

在这篇 paper 里，作者把“真 polar 因子”记作 $O(M_k)$ ，把“实际算出来的近似量”记作 $T(M_k)$ 。如果你不是精确拿到 $O(M_k)$ ，而只是拿到一个近似 $T(M_k)$ ，那就叫 inexact polar decomposition。文中直接用下面这种方式建模：

$$\|T(M_k) - O(M_k)\|_F \leq \Delta_k$$

或其期望版本。 MuonNesterov

这意味着：算法真正执行的是

$$X_{k+1} = X_k - \eta T(M_k),$$

而不是理想化的

$$X_{k+1} = X_k - \eta O(M_k).$$

也正因为如此，C 部分专门分析“近似 polar 会把收敛结论劣化多少”。Theorem C.1 说得很直白：原本理想情况下的主下降项会被削弱成

$$(1 - \Delta_k)\|M_k\|_*,$$

而误差放大项会变成

$$(\sqrt{d} + \Delta_k)\|\nabla f(X_k) - M_k\|_*.$$

也就是说， Δ_k 越大，近似越差，下降保证越弱。 MuonNesterov

为什么 Muon 要用这种 polar 因子，而不是直接用 M_k 本身？

从 paper 的分析能看出来一个关键性质：如果 $M_k = U_k \Sigma_k W_k^\top$ ，那么

$$O(M_k) = U_k W_k^\top,$$

而且

$$\langle M_k, O(M_k) \rangle = \|M_k\|_*.$$

这让下降分析特别干净，因为更新方向是“正交化”的，长度也容易控制。文中多处都在用这个性质。

 MuonNesterov  MuonNesterov

所以把三者压成一句话：

polar decomposition 是 Muon 想用的理想方向；Newton–Schulz 是 Muon 实际上用来近似这个方向的算法；inexact polar decomposition 就是“实际算出来的 $T(M)$ 和理想的 $O(M)$ 有误差”。

你也可以记成这张关系图：

$$\begin{array}{ccc} M_k & \xrightarrow{\text{理想定义}} & O(M_k) \\ M_k & \xrightarrow{\text{实际数值算法, 如 NewtonSchulz}} & T(M_k) \approx O(M_k) \end{array}$$

如果你愿意，我下一条可以直接给你举一个 2×2 矩阵的 polar decomposition / Newton-Schulz / inexact approximation 的具体例子。

Sources

     ...

近似

T

(

M

k

)

T(M

k

)就是用Newton-Schulz 或 Polar Express算的吗

Thought for a couple of seconds

对，这篇 paper 里的 近似 $T(M_k)$ ，就是在说：实际计算时不直接拿到真 polar 因子 $O(M_k)$ ，而是用数值方法去近似它；文中点名的就是 Newton–Schulz 或 Polar Express。  MuonNesterov  MuonNesterov

文里的关系基本就是：

$$O(M_k) = \text{true polar factor}, \quad T(M_k) \approx O(M_k)$$

而这个近似误差被写成

$$\|T(M_k) - O(M_k)\|_F \leq \Delta_k$$

或其期望版本。  MuonNesterov

所以更准确地说：

- $O(M_k)$ ：理想的、精确的 polar decomposition 结果
- $T(M_k)$ ：实际算法算出来的近似结果
- Newton–Schulz / Polar Express：用来从 M_k 计算 $T(M_k)$ 的具体数值方法  MuonNesterov

一句话：

是的，paper 里的近似 $T(M_k)$ 就是在抽象表示“用 Newton–Schulz 或 Polar Express 这类方法算出来的 polar 近似”。

你可以把我问的所有的assumptions, lemma, theorem, 主要story line 都用简短的话, 最好是一句话总结一下吗, 一个point是一个bullet point 这样

Thought for 22s >

可以, 下面给你一个**速记版总表**, 尽量都压成一句话一个点。

Main story line

- 这篇 paper 的主线是: **分析带 Nesterov momentum 的 Muon, 在 exact / inexact polar decomposition、以及 heavy-tailed stochastic gradient noise 下是否仍然收敛。**  MuonNesterov
- B 部分先做 **exact polar + heavy-tail noise** 的理论, 证明平均梯度范数可控并给出 sample complexity。  MuonNesterov  MuonNesterov
- C 部分再做 **inexact polar** 的理论, 证明即使 $T(M_k) \neq O(M_k)$, 只要近似误差小, 仍能得到收敛保证。  MuonNesterov
- D 部分回顾一套 **previous analysis**, 说明旧分析主要是按“距离到最优点 + 三类误差”来做。  MuonNesterov

Assumptions

- A.1: f 是 L -smooth, 也就是函数值可以用一阶项加二次上界控制。  MuonNesterov
- A.2: f 是 μ -strongly convex, 也就是函数有全局曲率下界。  MuonNesterov
- A.3: 随机梯度 G_k 无偏且方差有界, 这是普通 finite-variance 噪声假设。  MuonNesterov
- A.4: 随机梯度 G_k 无偏且只有 $\alpha \in (1, 2]$ 阶矩有界, 这是 heavy-tail 噪声假设。  MuonNesterov
- A.5: 近似 polar 因子 $T(M_k)$ 和真 polar 因子 $O(M_k)$ 的误差逐步被 $\Delta_k < 1$ 控制。  MuonNesterov
- A.6: 近似 polar 误差的条件期望也可以被一个统一常数 $\Delta < 1$ 控制。  MuonNesterov
- B.1: 单样本梯度噪声只要求 α -阶矩有界, 并允许噪声大小和真梯度大小耦合, 所以是 generalized heavy-tailed noise。  MuonNesterov
- D.2: previous analysis 里把 inexact polar 直接抽象成 $\|T(M_k) - O(M_k)\|_F \leq \Delta_k$ 。  MuonNesterov

B 部分: exact polar + heavy-tail

- Lemma B.2:** batch 平均后的梯度噪声 α -矩会按 $B^{-(\alpha-1)}$ 缩小, 所以大 batch 能压 heavy-tail 噪声。  MuonNesterov
- Lemma B.3:** 累计梯度范数由“初始函数差 + 平滑性代价 + 方向误差 ϵ_k 的累计”共同上界。  MuonNesterov
- Lemma B.4:** ϵ_k 可以精确展开成“初始误差衰减 + 梯度漂移累积 + 历史噪声累积”。  MuonNesterov
- Lemma B.5:** 在 heavy-tail 假设下, $\mathbb{E}\|\epsilon_k\|_F$ 可以被初始误差、smoothness 漂移、底噪项和梯度耦合噪声项一起控制。  MuonNesterov
- Theorem B.6:** 只要稳定性常数 $\rho > 0$, Muon 的平均梯度范数就能被步长、动量、batch、大尾噪声强度和初始化共同上界。  MuonNesterov
- B.1 Sample Complexity:** 为达到 $O(\epsilon)$ 精度, 可取 $K = O(\epsilon^{-2})$ 、 $B = O(\epsilon^{-\alpha/(\alpha-1)})$, 所以总样本复杂度是 $O(\epsilon^{-(3\alpha-2)/(\alpha-1)})$ 。  MuonNesterov
- B.2 Parameters Independent of α :** 作者想说明可以选一组不显式依赖 α 的 β, η 来得到收敛率, 但最终复杂度仍会体现 α 的影响。  MuonNesterov
- Lemma B.7:** 累计梯度范数可以由初始函数差、累计方向误差 $M_k - \nabla f(X_k)$ 和步长平方项控制。  MuonNesterov
- Lemma B.8:** 误差 $S_k = M_k - \nabla f(X_k)$ 可以展开成初始梯度项、历史梯度的几何加权、以及历史噪声的几何加权。  MuonNesterov
- Lemma B.9:** 对 B.8 取期望后可得 S_k 由初始梯度残差、历史梯度和 heavy-tail 噪声共同控制。  MuonNesterov

- Theorem B.10: 只要 batch 足够大且动量足够小使 $\rho > 0$, exact-polar 的 Muon 在 heavy-tail 噪声下有平均梯度收敛保证。  MuonNesterov
- Remark B.11: 如果 $\sigma_1 = 0$, 也就是噪声不和梯度大小耦合, 那么不再需要大 batch, 下界条件主要只剩对 β 的限制。  MuonNesterov
- B.4 Sample Complexity: 基于 Theorem B.10 再推一遍, 一般 heavy-tail 情况下仍得到 $K = O(\varepsilon^{-2})$ 、 $B = O(\varepsilon^{-\alpha/(\alpha-1)})$ 和同阶总样本复杂度。  MuonNesterov
- B.5 Parameters Independent of α : 在 $\sigma_1 = 0$ 的更容易情形下, 理论条件更宽松, 甚至可以考虑 $B = 1$; 不过你这份文件里这一节正文是截断的。  MuonNesterov

C 部分: inexact polar

- Theorem C.1: 如果实际更新用的是近似 polar $T(M_k)$, 那么单步下降仍成立, 但主下降项会被 $(1 - \Delta_k)$ 削弱、误差项会被 $(\sqrt{d} + \Delta_k)$ 放大。  MuonNesterov
- Theorem C.2: 把 C.1 从单步累加到 K 步后, 可得到累计梯度范数由初始函数差、累计方向误差和步长平方项控制。  MuonNesterov
- Lemma C.3: 在 finite-variance 情况下, 只要 β 不太大, 累计误差 $\sum_k \mathbb{E} \|S_k\|_*^2$ 可以由初始动量、梯度平方和和噪声方差控制。  MuonNesterov
- Theorem C.4: 在 inexact polar + finite-variance 下, 只要稳定性常数 $\rho > 0$, 那么前 K 步里至少有一步的期望梯度范数会很小。  MuonNesterov
- Lemma C.5: 给出一个对所有 $\alpha \in (1, 2]$ 都适用的 nonlinear Young inequality, 用来在 heavy-tail 情况下拆分 $\|A + B\|^\alpha$ 。  MuonNesterov
- Lemma C.6: 在 heavy-tail 情况下, 只要 $(1 + \varepsilon)\beta^\alpha < 1$, 累计误差 $\sum_k \mathbb{E} \|S_k\|_*^\alpha$ 仍能被初始动量、梯度 α -矩和噪声 α -矩控制。  MuonNesterov

D 部分: previous analysis

- Previous Analysis: 旧分析的基本想法是研究 $\|X_{k+1} - X^*\|_F^2$ 的递推, 再把误差拆成近似 polar 误差、polar 本身的变化和动量漂移三块。  MuonNesterov
- Lemma D.1: 一步更新后的到最优点平方距离由“上一时刻距离项 - 函数下降项 + 更新方向误差 $\|T(M_k) - G_k\|^2$ + 方差项”共同控制。  MuonNesterov

你问过的几个核心概念

- Heavy-tail: 这里指的是 stochastic gradient / gradient noise heavy-tailed, 而不是 paper 直接对 data distribution 做 heavy-tail 建模。  MuonNesterov
- Polar decomposition: 对矩阵 M 的 polar 因子 $O(M)$ 是 Muon 想用的理想更新方向。  MuonNesterov
- Newton-Schulz / Polar Express: 它们不是 polar decomposition 本身, 而是实际用来近似计算 polar 因子的数值方法。  MuonNesterov  MuonNesterov
- Inexact polar decomposition: 就是实际算出来的是 $T(M_k) \approx O(M_k)$, 并且误差用 Δ_k 或 Δ 来控制。  MuonNesterov  MuonNesterov

整篇 paper 的一句话总总结

- 这篇 paper 的总结论是: 带 Nesterov momentum 的 Muon, 在 exact 或 mildly inexact 的 polar decomposition 下, 即使 stochastic gradient 噪声是 heavy-tailed, 也仍然能建立收敛理论; 但 batch、动量和近似误差必须配合得当。  MuonNesterov  MuonNesterov  MuonNesterov

我也可以下一条把这些内容压成一页***“口头汇报提纲版”**, 只保留最重要的 10 条。

Sources

     ...

我想做一些实验来support这个paper, 你建议做什么实验

我先按“最能直接支撑 paper 主张”的优先级来给你排实验: 先做能验证 exact/inexact polar 和 heavy-tail 两条主线的, 再做更贴近真实训练的补充。

如果你的目标是“用实验把这篇 paper 的主张撑起来”，我建议不要一上来做大而杂的 benchmark，而是围绕它最核心的 4 个 claim 来设计：

(1) exact polar 下 heavy-tail 也能收敛，(2) batch 和 α 会影响稳定性/复杂度，(3) inexact polar 会按 Δ 劣化收敛，(4) $\sigma_1 = 0$ 比 $\sigma_1 > 0$ 明显更容易。  MuonNesterov  MuonNesterov  MuonNesterov  MuonNesterov

我会建议你做下面这几组实验：

- **实验 1: theorem-aligned 的合成优化实验。**

选一个你能精确控制的矩阵优化问题，比如二次目标 $f(X) = \frac{1}{2} \|X - X^*\|_F^2$ 或更一般的 smooth matrix objective；这样真梯度已知、exact polar 可以用 SVD 算、inexact polar 可以单独替换成 Newton-Schulz / Polar Express，最容易直接对应 paper 的理论对象。  MuonNesterov

- **实验 2: heavy-tail 强度 α 的 ablation。**

人工构造 stochastic gradient noise，让它只满足 $\alpha \in (1, 2]$ 阶矩控制；例如做几组不同尾部强度的噪声，然后比较训练曲线、平均梯度范数、稳定性和失败率，看 α 变小以后训练是否更难、更依赖大 batch，这直接对应 B.1/B.4 的主张。  MuonNesterov  MuonNesterov  MuonNesterov

- **实验 3: batch size B 扫描。**

固定其它量，只扫 batch，观察平均梯度范数、loss、最终误差和稳定性；最关键的是做 log-log 图，看 batch 变大时 heavy-tail 噪声影响是否明显减弱，这能支撑“大 batch 压重尾噪声”和 sample complexity 里 B 的角色。  MuonNesterov  MuonNesterov  MuonNesterov

- **实验 4: exact polar vs Newton-Schulz / Polar Express。**

用 SVD 计算的 exact polar 当 oracle，再和 Newton-Schulz 不同步数、Polar Express 做对比；同时记录

$$\Delta_k = \|T(M_k) - O(M_k)\|_F$$

和训练下降速度，看看 Δ_k 越大时，下降项是否越差、训练是否越不稳，这就是对 C.1/C.2 最直接的实验支撑。  MuonNesterov  MuonNesterov

- **实验 5: inexact polar 精度 ablation。**

不只比较“算法 A vs 算法 B”，而是系统地扫近似精度，比如 Newton-Schulz 迭代步数 1, 2, 3, 5, 10；然后看 Δ_k 、平均梯度范数、最终 loss、以及 divergence rate 随精度变化的趋势，这比只做一条 baseline 更能支撑 paper 的理论故事。  MuonNesterov  MuonNesterov

- **实验 6: $\sigma_1 = 0$ vs $\sigma_1 > 0$ 的对照。**

做两种噪声：一种是纯加性 heavy-tail 噪声（近似对应 $\sigma_1 = 0$ ），一种让噪声强度随 $\|\nabla f(X_k)\|$ 增大（近似对应 $\sigma_1 > 0$ ）；然后比较小 batch 下谁更容易炸、谁更需要大 batch，这能直接支撑 Remark B.11 和 B.5 的叙事。  MuonNesterov

- **实验 7: momentum β 扫描。**

这篇 paper 反复强调 β 太大时稳定性常数 ρ 会变差，所以你应该固定其它量，扫一条 β 曲线，尤其在 heavy-tail 和 inexact polar 条件下看性能拐点，这会非常贴合定理。  MuonNesterov  MuonNesterov

 MuonNesterov

- **实验 8: 一个小型真实训练任务做 sanity check。**

在一个中小规模模型上跑真实训练，重点不是追 SOTA，而是看 synthetic 里观察到的规律是否还在：大尾噪声时更依赖 batch，inexact polar 精度差时更不稳，较大 β 更容易出问题；这能证明你的理论支撑不是只存在于 toy setup。  MuonNesterov  MuonNesterov

我建议你**重点汇报的指标**不要只放 train/val loss，最好至少加上这 5 个：

- 平均梯度范数，直接对应 B.6 / B.10 的结论。  MuonNesterov  MuonNesterov
- 前 K 步里的最小梯度范数，直接对应 C.4。  MuonNesterov
- $\Delta_k = \|T(M_k) - O(M_k)\|_F$ ，直接对应 inexact polar 理论。  MuonNesterov  MuonNesterov
- $\|S_k\| = \|M_k - \nabla f(X_k)\|$ 或 $\|\epsilon_k\|$ ，验证“方向误差”这条中间机制。  MuonNesterov  MuonNesterov
- 多 seed 下的稳定性/失败率，因为 heavy-tail 和 inexact polar 的区别很多时候体现在“偶发极端不稳定”。  MuonNesterov  MuonNesterov

如果你想要一个**最小但足够强的实验包**，我会选这 4 个：

- 一个 synthetic exact-polar heavy-tail 实验
- 一个 α / batch 的 scaling 实验
- 一个 exact vs inexact polar 精度 ablation
- 一个 $\sigma_1 = 0$ vs $\sigma_1 > 0$ 对照

这 4 个最贴 paper 的主线，也最容易写成“每个实验都在验证一个 theorem/remark”。

一个很重要的提醒：

这篇 paper 的理论大多是关于 gradient norm / stationarity，不是关于 test accuracy。所以你的实验如果只报 accuracy，会显得和理论脱节；最好把 theorem-aligned 指标放在主图里，accuracy 放补充。

 MuonNesterov

 MuonNesterov

 MuonNesterov

如果你愿意，我下一条可以直接给你整理成一个“实验章节提纲 + 每个实验对应支撑哪条 theorem”的版本。

Sources

     ...

主要是heavy tail怎么做呢

已思考几秒

如果你问的是 实验里怎么“做出 heavy tail”，最实用的做法是：

不要先想 data heavy-tail，先直接对 stochastic gradient / gradient noise 做 heavy-tail 注入。

因为这篇 paper 理论上建模的就是

$$G_k^i - \nabla f(X_k)$$

是 heavy-tailed，而不是直接建模数据分布本身。  MuonNesterov

我建议你分三档来做。

1. 最干净、最贴 paper 的做法：直接给梯度加 heavy-tail 噪声

在 synthetic problem 里，真梯度 $\nabla f(X_k)$ 是已知的，于是你直接构造

$$G_k^i = \nabla f(X_k) + \xi_k^i$$

其中 ξ_k^i 来自 heavy-tailed 分布。

最推荐的几种：

- **Student-t 噪声**：最容易实现，也最常用；自由度 ν 越小尾巴越重。
- **Pareto / symmetric Pareto 噪声**：更“典型重尾”，但数值上更暴躁。
- **混合高斯噪声**：例如 99% 小方差高斯 + 1% 超大方差高斯；它不一定严格对应 $\alpha < 2$ ，但很适合制造“偶发巨大梯度”的现象。
- **Lévy-stable / α -stable 噪声**：最贴“只有 α -moment、甚至方差可能不存在”的设定，但实现和调参会更麻烦。

如果你是为了 support 这篇 paper，优先级我建议是：

Student-t > symmetric Pareto > Gaussian mixture > stable

因为 Student-t 最稳妥、最容易复现，也最容易扫“尾部强度”。

2. 怎么让它更贴 B.1 的假设

B.1 不是简单说“噪声有重尾”，而是说

$$\mathbb{E}[\|\xi_k^i\|^\alpha \mid X_k] \leq \sigma_0^\alpha + \sigma_1^\alpha \|\nabla f(X_k)\|^\alpha.$$

也就是说噪声可以有两部分：

- **固定底噪**： σ_0
- **随梯度变大的噪声**： $\sigma_1 \|\nabla f(X_k)\|$

所以实验里最好做两种版本：

版本 A: $\sigma_1 = 0$ 的纯加性 heavy-tail

直接设

$$\xi_k^i = \sigma_0 z_k^i,$$

其中 z_k^i 是重尾噪声。

这对应 paper 里更容易的情形，也对应 Remark B.11 / B.5。  MuonNesterov

版本 B: $\sigma_1 > 0$ 的梯度相关 heavy-tail

设

$$\xi_k^i = (\sigma_0 + \sigma_1 \|\nabla f(X_k)\|) z_k^i$$

或者更平滑一点

$$\xi_k^i = \sigma_0 z_k^i + \sigma_1 \|\nabla f(X_k)\| z_k^{i'}.$$

这就更贴 paper 的 generalized heavy-tailed noise。

然后你可以直接做 $\sigma_1 = 0$ vs $\sigma_1 > 0$ 对照实验。  MuonNesterov

3. 最关键的变量：怎么调“尾巴有多重”

你需要一个能系统调的“heavy-tail 强度”旋钮。

最方便的是：

- Student-t: 扫自由度 ν ，比如 $\nu \in \{1.5, 2, 3, 5, 10, \infty\}$
 - ν 越小，尾巴越重
 - $\nu \rightarrow \infty$ 近似高斯
- Pareto: 扫 tail index
- Gaussian mixture: 扫“大爆点”出现概率 p 和大方差倍数

如果你是为了贴 paper 里的 $\alpha \in (1, 2]$ ，可以把实验叙述成：

- 较大的 ν / 较轻尾：接近有限方差
- 较小的 ν / 较重尾：更接近文中 heavy-tail setting

严格——对应不一定太死，因为论文本身也不是要求你真的采样某个唯一分布；关键是制造“极端梯度更常出现”的 regime。

4. 一个最推荐的具体 recipe

如果你想马上开跑，我建议你先这样做：

Synthetic objective

$$f(X) = \frac{1}{2} \|X - X^*\|_F^2$$

这样

$$\nabla f(X) = X - X^*$$

很好算。

Stochastic gradient

对每步、每个样本构造

$$G_k^i = \nabla f(X_k) + \xi_k^i$$

Heavy-tail 噪声

先用 Student-t:

$$\xi_k^i = s_k \cdot z_k^i, \quad z_k^i \sim t_\nu$$

其中：

- 纯加性版: $s_k = \sigma_0$
- 梯度相关版: $s_k = \sigma_0 + \sigma_1 \|\nabla f(X_k)\|_F$

扫描

扫这几个量:

- ν : 比如 2, 3, 5, 10
- B : 比如 1, 4, 16, 64, 256
- β : 比如 0, 0.5, 0.8, 0.9
- polar 近似步数: 比如 Newton-Schulz 1, 2, 3, 5, exact

记录

- $\frac{1}{K} \sum_k \|\nabla f(X_k)\|_F$
- 最小梯度范数
- training loss
- $\|T(M_k) - O(M_k)\|_F$
- failure/divergence rate
- 多 seed 方差

这套已经足够撑起 paper 的大部分故事。

5. 如果你想从“数据”层面做 heavy-tail

也可以, 但我不建议先这样做, 因为不够干净。

常见办法:

- 让输入特征 x 来自 heavy-tailed 分布
- 让 label noise / residual 是 heavy-tailed
- 往数据里加少量超大离群点
- 做极端不平衡 / 稀有难样本

这样会让 per-sample gradient 变重尾。

但问题是: 你很难分清到底是“模型结构”还是“数据分布”在起作用。对支持这篇 paper 来说, 不如直接在梯度层造噪声更有说服力。

6. 你怎么证明自己真的造出了 heavy tail

这个很重要, 不然 reviewer 会觉得你只是“加了大噪声”。

建议至少做 3 个检查:

- 画单样本梯度范数 $\|G_k^i - \nabla f(X_k)\|$ 的直方图/CCDF
- 做 log-log tail plot
- 报样本分位数, 比如 95%、99%、99.9% 分位数

如果重尾版本的 99.9% 分位数远高于高斯版本, 就很直观。

7. 我最推荐的起步方案

如果你现在只想先做一个靠谱版本:

先做 synthetic quadratic + Student-t gradient noise + 两种设定 $\sigma_1 = 0$ 和 $\sigma_1 > 0$ + batch sweep。

这是最贴 paper、最容易解释、最不容易跑偏的方案。

一句话总结:

做 heavy-tail 最好的办法, 是直接把 stochastic gradient 写成“真梯度 + 重尾噪声”, 先用 Student-t 做纯加性和梯度相关两种版本, 再扫 batch、momentum 和 polar 近似精度。

你要的话, 我下一条可以直接给你一版 PyTorch 伪代码, 把这个 heavy-tail gradient generator 写出来。

Sources

我还想在nanogpt和cifar10上做，synthetic也可以，但这咋做啊

我给你按“synthetic / CIFAR-10 / nanoGPT”三条线分别落到可操作层面，这样你能直接开工，而不是停留在概念上。

已思考 4s

可以，而且我建议你就按 三层实验 来做：

synthetic 负责对 theorem，CIFAR-10 负责中等规模可验证，nanoGPT 负责真实大模型训练现象。

最关键的是：heavy-tail 不一定非要从 data distribution 本身造出来；最稳妥的是在训练时对 stochastic gradient 做 controllable 的重尾扰动。这最贴 paper 的假设。  MuonNesterov

一、总的实验设计框架

你可以把实验分成三组问题：

- Q1: heavy-tail 越重，Muon 越不稳定吗？大 batch 能不能救？
- Q2: exact polar 和 inexact polar 的差距，是否随 Δ 变大而恶化？
- Q3: $\sigma_1 = 0$ 和 $\sigma_1 > 0$ 的区别，是否真的像理论说的那样？  MuonNesterov

对应地，三条实验线都尽量统一成这些变量：

- tail strength: 轻尾 vs 重尾
- batch size: 小到大
- momentum β : 小到大
- polar precision: exact / NS-1 / NS-2 / NS-3 / ...
- noise type: $\sigma_1 = 0$ vs $\sigma_1 > 0$

二、Synthetic：最重要，最贴 theorem

这是你最应该先做的，因为它最容易和 paper 的 lemma / theorem 一一对应。

怎么做

选一个矩阵优化目标，比如

$$f(X) = \frac{1}{2} \|X - X^*\|_F^2$$

或者

$$f(X) = \frac{1}{2} \|AX - B\|_F^2.$$

这样你知道真梯度：

$$\nabla f(X) = X - X^* \quad \text{或} \quad A^\top (AX - B).$$

然后构造单样本梯度：

$$G_k^i = \nabla f(X_k) + \xi_k^i$$

其中 ξ_k^i 是你手工加的 heavy-tail 噪声。

heavy-tail 怎么造

最推荐直接用 Student-t:

- 纯加法版：

$$\xi_k^i = \sigma_0 z_k^i$$

- 梯度相关版：

$$\xi_k^i = (\sigma_0 + \sigma_1 \|\nabla f(X_k)\|_F) z_k^i$$

这里 $z_k^i \sim t_\nu$, ν 越小尾巴越重。

你测什么

- average gradient norm
- min gradient norm
- loss
- $\|M_k - \nabla f(X_k)\|_F$
- exact vs inexact polar gap：

$$\Delta_k = \|T(M_k) - O(M_k)\|_F$$

为什么它重要

因为这能直接验证：

- B.1/B.4 的 batch scaling
- B.6/B.10 的 average gradient bound
- C.1/C.2 的 inexact polar effect  MuonNesterov  MuonNesterov  MuonNesterov

三、CIFAR-10：最容易做、最适合先出图

CIFAR-10 是最适合你快速做“真实深度网络 + 可控 heavy-tail”实验的。

方案 A：不改数据，直接改训练梯度

这是我最推荐的。

训练一个小模型，比如：

- ResNet-18
- 小型 CNN
- ViT-Tiny 也行，但先别上太复杂

然后在 optimizer step 前，对每个参数梯度做重尾扰动：

$$g \leftarrow g + s_t \cdot z$$

其中 z 来自 Student-t, s_t 可以是：

- 常数 σ_0
- 或者跟当前整体梯度范数成比例：

$$s_t = \sigma_0 + \sigma_1 \|g\|$$

这样你就在真实训练里模拟了 B.1 的两种情况。

PyTorch 里怎么实现

核心就是在 `loss.backward()` 后、`optimizer.step()` 前加：

```
for p in model.parameters():
    if p.grad is None:
        continue
    z = sample_student_t_like(p.grad, df=df) # same shape
    scale = sigma0
    # gradient-coupled version:
    # scale = sigma0 + sigma1 * global_grad_norm
    p.grad.add_(scale * z)
```

方案 B：做“data-induced heavy tail”

也可以，但作为补充，不要当主实验。

比如：

- 给一小部分训练样本加超大幅度像素扰动
- 加少量 label corruption
- 制造 class imbalance
- 混入少量 outlier images

这样 per-example gradient 会变长尾，但解释起来不如直接梯度注入干净。

CIFAR-10 上建议做的对照

- SGD / AdamW / Muon
- Muon + exact polar surrogate (小层可做)
- Muon + Newton-Schulz 1/2/3 步
- heavy-tail off / on
- $\sigma_1 = 0 / \sigma_1 > 0$
- batch 128 / 512 / 2048

CIFAR-10 上主要看什么

- train loss
- test accuracy
- gradient norm trajectory
- instability rate (loss spike / NaN / divergence)
- 多 seed 方差

这里 accuracy 可以报，但最好把 **gradient norm / stability** 放主图，因为 paper 的理论核心不是 accuracy。

 MuonNesterov  MuonNesterov

四、nanoGPT：更真实，但做法要稍微克制

在 nanoGPT 上，最现实的方式也是直接在梯度层注入 heavy-tail，而不是试图从文本数据本身造出可控重尾。

为什么

如果你去改文本分布，很难解释到底是：

- token frequency
- sequence length
- rare contexts
- optimizer dynamics

哪个在起作用。

但如果你直接控制 gradient noise，你就能更干净地 support 论文。

怎么做

训练 nanoGPT 时，在 backward 之后注入：

$$g \leftarrow g + s_t z, \quad z \sim t_\nu$$

建议先只做两种：

- **additive heavy-tail**: $s_t = \sigma_0$
- **gradient-coupled heavy-tail**: $s_t = \sigma_0 + \sigma_1 \|g\|_{\text{global}}$

其中 global grad norm 可以每 step 先算出来。

nanoGPT 上别做太多变量

不然训练成本会爆。

最小方案建议只扫：

- heavy-tail strength：无 / 中 / 强
- batch size：小 / 大
- polar precision：低 / 高

- β : 低 / 高

nanoGPT 上建议看的指标

- training loss / val loss
- tokens-per-second 或 step time
- gradient norm
- spike / divergence 次数
- 同等 wall-clock 下的 loss
- 同等 token budget 下的 loss

一个特别好的图

横轴 = polar approximation cost, 纵轴 = final val loss 或 stability

这样可以展示：更精确的 polar 近似是否值得计算代价。

五、你最关心的：“exact polar” 在 CIFAR/nanoGPT 上怎么搞？

这个确实是现实问题。

在大模型里，不可能对所有大矩阵层都频繁做 full SVD 当 oracle。

所以建议这样：

在 synthetic 上

直接用 SVD 算 exact polar，当真 oracle。

在 CIFAR-10 上

可以只对 小层 / 小模型 做 exact polar oracle，作为验证。

比如：

- 小 CNN
- bottleneck 层
- 小 hidden dim MLP

在 nanoGPT 上

不要追求全模型 exact polar。你可以做三种替代：

- 用更多步 Newton-Schulz 当“更精确近似”
- 对一个小子层做 oracle 检查
- 离线抽样若干 step、若干层，单独计算 exact polar 和 $T(M)$ 的 gap

也就是说，nanoGPT 上你更应该验证“近似精度提升是否改善训练”，而不是强行全程 exact-oracle 对照。

六、最推荐的实际落地顺序

Phase 1: 先把图跑出来

1. Synthetic + Student-t heavy-tail + batch sweep
2. Synthetic + exact vs NS steps
3. CIFAR-10 + gradient heavy-tail injection
4. CIFAR-10 + $\sigma_1 = 0$ vs $\sigma_1 > 0$

Phase 2: 再上 nanoGPT

5. nanoGPT + additive heavy-tail
6. nanoGPT + gradient-coupled heavy-tail
7. nanoGPT + NS precision / momentum / batch ablation

七、如果你时间有限，只做这 4 个实验

我会选：

- Synthetic: heavy-tail strength $\times$ batch
- Synthetic: exact polar vs inexact polar
- CIFAR-10: heavy-tail on/off $\times$ batch
- nanoGPT: heavy-tail on/off $\times$ polar precision

这四个已经足够撑起 paper 的主 story line。

八、你可以直接写进论文的实验 claim

你最后可以把实验章节写成这几个 claim：

- “Heavy-tailed gradient noise significantly destabilizes Muon at small batch sizes, while larger batches restore stability.”
- “The degradation caused by inexact polar decomposition correlates with the approximation error Δ .”
- “Gradient-coupled heavy-tail noise is substantially harder than additive heavy-tail noise.”
- “The empirical sensitivity to momentum and batch size matches the qualitative predictions of the theory.”

这些都和 paper 的 theorem/remark 对得上。  MuonNesterov  MuonNesterov

如果你愿意，我下一条可以直接给你一个 **CIFAR-10 / nanoGPT 的具体代码改动点清单**，包括在训练循环哪里插 heavy-tail gradient injection。

Sources

     ...

我的意思是你说的这些全部的实验在nanogpt, cifar10上咋做，整理一下

已思考若干秒

可以，我给你整理成一个**能直接执行的实验方案**，专门回答：

“把 paper 里想验证的东西，放到 CIFAR-10 和 nanoGPT 上，具体怎么做？”

总目标

你要验证的其实就 4 件事：

- heavy-tail 会不会让训练更不稳
- batch 变大能不能缓解
- inexact polar 会不会比更精确的 polar 更差
- $\sigma_1 = 0$ 和 $\sigma_1 > 0$ 有没有明显区别  MuonNesterov  MuonNesterov  MuonNesterov

所以不管是 CIFAR-10 还是 nanoGPT，实验结构都统一成：

- baseline：原始训练
- heavy-tail on/off
- additive vs gradient-coupled heavy-tail
- 小 batch vs 大 batch
- 粗糙 polar vs 精细 polar

一、统一实验变量

先把所有实验统一成这几个可控变量。

1. Heavy-tail 开关

两种：

- off：不加额外重尾扰动
- on：对梯度加 heavy-tail 噪声

2. Heavy-tail 类型

两种：

- additive（对应 $\sigma_1 = 0$ ）

$$g \leftarrow g + \sigma_0 z$$

- gradient-coupled（对应 $\sigma_1 > 0$ ）

$$g \leftarrow g + (\sigma_0 + \sigma_1 \|g\|) z$$

其中 z 是重尾随机变量，比如 Student-t。  MuonNesterov

3. Tail strength

推荐用 Student-t 自由度控制：

- 轻尾：df = 10
- 中等重尾：df = 3
- 强重尾：df = 2

df 越小，尾巴越重。

4. Batch size

至少两档：

- 小 batch
- 大 batch

这样能验证 B 部分的核心故事。  MuonNesterov  MuonNesterov

5. Polar precision

至少三档：

- 粗：Newton-Schulz 1 step
 - 中：Newton-Schulz 3 steps
 - 细：Newton-Schulz 5 steps
- 或者在小模型/小层上加一个 exact SVD oracle 对照

这对应 C 部分。  MuonNesterov

6. Momentum

至少两档：

- 小 β
- 大 β

因为 paper 一直强调 β 太大不稳。  MuonNesterov  MuonNesterov

二、CIFAR-10 上怎么做

CIFAR-10 最适合做可控、可重复、图好看的实验。

A. 任务和模型

建议先用一个简单又标准的模型：

- ResNet-18
- 或小 CNN

不要一开始就上太复杂模型。

B. 训练框架

你需要有一个 Muon optimizer 版本，里面有：

- momentum C_k, M_k
- polar update
- Newton–Schulz 近似步数可调

C. heavy-tail 怎么注入

最简单直接的方法：

在每次 `loss.backward()` 之后、`optimizer.step()` 之前，对每个参数的梯度做注入。

additive heavy-tail

对每个参数张量 p ：

$$p.grad \leftarrow p.grad + \sigma_0 z$$

gradient-coupled heavy-tail

先算全局梯度范数 G ：

$$G = \|g\|_{\text{global}}$$

然后

$$p.grad \leftarrow p.grad + (\sigma_0 + \sigma_1 G)z$$

这里 z 和 `p.grad` 同 shape，来自 `Student-t(df)`。

这一步就是你在真实训练里模拟 B.1 的 heavy-tail gradient noise。  MuonNesterov

D. CIFAR-10 上具体要跑什么

实验 C1: heavy-tail on/off

固定：

- batch
- β
- polar precision

对比：

- no heavy-tail
- additive heavy-tail
- gradient-coupled heavy-tail

看：

- train loss
- test accuracy
- gradient norm
- 是否出现 spike / divergence

实验 C2: batch sweep

固定：

- tail strength
- β
- polar precision

扫：

- batch = 128 / 512 / 2048

看：

- 重尾下大 batch 是否明显更稳
- 同样训练步数下 loss 是否更低

实验 C3: polar precision sweep

固定：

- heavy-tail 开启
- batch
- β

扫：

- NS-1
- NS-3
- NS-5

看：

- 更精确的 polar 是否更稳
- test accuracy / loss 是否更好
- 梯度 norm spike 是否减少

实验 C4：momentum sweep

固定：

- heavy-tail 开启
- batch
- polar precision

扫：

- $\beta=0.5 / 0.8 / 0.9$

看：

- 大 β 是否更容易炸
- 和理论的 ρ 直觉是否一致

E. CIFAR-10 主图建议

主图不要只放 accuracy，建议放：

- train loss curve
- global grad norm curve
- final test accuracy
- divergence rate across seeds

三、nanoGPT 上怎么做

nanoGPT 更像“真实训练验证”。

A. 模型和训练设置

建议先用小模型：

- 小 context
- 小层数
- 小 hidden dim

先把实验跑通，再加规模。

B. heavy-tail 注入方式

跟 CIFAR-10 完全一样：

在 `backward()` 后、`optimizer.step()` 前，对所有参数梯度加重尾扰动。

additive

$$g \leftarrow g + \sigma_0 z$$

gradient-coupled

$$g \leftarrow g + (\sigma_0 + \sigma_1 \|g\|_{\text{global}}) z$$

因为 nanoGPT 训练贵，建议不要扫太多变量。

C. nanoGPT 上具体要跑什么

实验 N1: heavy-tail on/off

固定:

- batch
- β
- polar precision

对比:

- no heavy-tail
- additive heavy-tail
- gradient-coupled heavy-tail

看:

- train loss
- val loss
- gradient norm
- spike / divergence

实验 N2: batch 对照

固定:

- heavy-tail on
- β
- polar precision

对比:

- 小 batch
- 大 batch

看:

- 大 batch 是否明显改善稳定性

实验 N3: polar precision 对照

固定:

- heavy-tail on
- batch
- β

对比:

- NS-1
- NS-3
- NS-5

看:

- 更精确 polar 是否有更低 val loss / 更少梯度爆点

实验 N4: $\sigma_1 = 0$ vs $\sigma_1 > 0$

固定:

- heavy-tail 强度
- batch
- β
- polar precision

对比:

- additive heavy-tail
- gradient-coupled heavy-tail

看:

- gradient-coupled 是否更难训练
- 是否更依赖大 batch

D. nanoGPT 该看哪些指标

最重要的是：

- train loss
- val loss
- global grad norm
- divergence count
- 同等 token budget 下的 final val loss
- 同等 wall-clock 下的 final val loss

nanoGPT 上 accuracy 不是重点，loss/stability 才是。

四、exact polar 在 CIFAR / nanoGPT 上怎么处理

这是最现实的问题。

CIFAR-10

可以做两种：

- 全模型都只用 NS steps，做 1/3/5 步对照
- 对少数小层做 exact SVD oracle 检查

也就是：

- 训练时大部分用近似
- 评估时抽样若干层若干步，算

$$\Delta_k = \|T(M_k) - O(M_k)\|_F$$

nanoGPT

不要强行全模型 exact polar。

建议：

- 训练时只用 NS steps
- 离线抽样若干 step、若干层
- 对这些样本用 SVD 算 exact polar
- 记录 Δ_k

这样你就能说：

“更高 NS steps 的确减小了 Δ_k ，并改善了训练稳定性。”

这已经足够 support C 部分，不需要全程 exact oracle。  MuonNesterov

五、推荐的最小实验矩阵

如果你不想组合爆炸，我建议每个平台只跑这几组。

CIFAR-10 最小包

- baseline
- additive heavy-tail, small batch, NS-1
- additive heavy-tail, large batch, NS-1
- additive heavy-tail, large batch, NS-5
- gradient-coupled heavy-tail, small batch, NS-1
- gradient-coupled heavy-tail, large batch, NS-5

nanoGPT 最小包

- baseline
- additive heavy-tail, small batch, NS-1
- additive heavy-tail, large batch, NS-1
- additive heavy-tail, large batch, NS-5

- gradient-coupled heavy-tail, small batch, NS-1
- gradient-coupled heavy-tail, large batch, NS-5

这两套已经能讲完整个故事。

六、每个实验在 support 什么

你写 paper 时可以这样对齐。

- **heavy-tail on/off**: support “Muon 在 heavy-tail 下更难, 但仍可通过合适设置稳定”  MuNesterov
- **batch sweep**: support “大 batch 缓解 heavy-tail”  MuNesterov  MuNesterov
- **NS precision sweep**: support “inexact polar 误差会劣化下降”  MuNesterov
- $\sigma_1 = 0$ vs $\sigma_1 > 0$: support Remark B.11 / B.5 的特殊更容易情形  MuNesterov
- **momentum sweep**: support “大 β 更容易不稳”  MuNesterov  MuNesterov

七、训练代码里真正要改的地方

你最终只需要改两处。

1. backward 后加 heavy-tail

伪代码：

`</> Python`





2. optimizer 里控制 polar 精度

在 Muon optimizer 里暴露一个参数：

- ns_steps=1
- ns_steps=3
- ns_steps=5

或者 polar_method in {ns1, ns3, ns5}

这样你就能直接做 inexact polar ablation。

八、我最建议的执行顺序

1. 先 CIFAR-10 跑通

- baseline
- additive heavy-tail
- gradient-coupled heavy-tail
- batch 小/大
- NS-1/5

2. 再上 nanoGPT

- 不要一开始扫太多
- 先做 6 个最小组合

3. 最后再补 synthetic

- 用来给 theorem-aligned 图
- 尤其补 Δ_k 、 $\|M_k - \nabla f(X_k)\|$ 这些真实任务里难精确测的量

九、一句话版

在 CIFAR-10 和 nanoGPT 上，你就统一用“backward 后给梯度加 Student-t 重尾扰动 + optimizer 里扫 Newton-Schulz 近似步数 + 对比小/大 batch、 $\sigma_1 = 0/\sigma_1 > 0$ 、小/大 β ”这套框架，就能把这篇 paper 的 heavy-tail 和 inexact polar 主线基本都验证掉。

如果你要，我下一条可以直接给你整理成一个 **表格版实验计划**，列成“平台 / 变量 / 取值 / 指标 / 对应支撑哪条 theorem”。

Sources

