

讲解主要讲了什么东西，哪些theorem是重要的，对实验有指导意义，或者需要实验support的

我先通读这篇 PDF，把内容分成三块：主线结论、关键定理、以及哪些地方最该靠实验去验证。

我已经定位到论文主线了：核心不是提出一个新 optimizer，而是给 “Muon + Nesterov momentum + inexact polar / Newton–Schulz” 做一套理论分析，并把实验该验证的点也点出来。接着我把关键 theorem 的层级再理一遍。

Thought for 1m 38s >

我看下来，这篇稿子**主要是在做理论工作**：给 Muon + Nesterov momentum 建立收敛分析，并且把分析从“精确 polar decomposition”推广到“inexact polar（尤其是 Newton–Schulz 近似）”，同时允许 heavy-tailed stochastic gradient noise。作者自己列的主贡献也是这几条：首次分析带 Nesterov 的 Muon、放宽随机梯度假设、给出 sample complexity、讨论不需要知道噪声指数 α 的参数选择，以及把 Newton–Schulz 纳入统一的 inexact polar 框架。就目前这版来看，**实验部分还是计划清单，不像已经完整跑完的结果部分。**

 MuonNesterov (1)  MuonNesterov (1)

最重要的 theorem / lemma，我会分成“必读”和“辅助”两层。

第一层，**必读的核心结果**：

1. **Theorem 3.6**：证明了做了若干步 cubic Newton–Schulz 之后得到的 $T_q(M)$ ，确实满足文中定义的 inexact polar 条件；而且还能把误差写成一个显式的 $\delta_q(M)$ 。这一定理很关键，因为它把“工程上常用的近似正交化”合法地接进了理论框架。没有它，后面的 inexact 分析就是悬空的。  MuonNesterov (1)
2. **Theorem A.4**：这是 exact polar 情况下的主收敛界。它把平均梯度范数上界拆成几个来源：优化误差项、平滑项、初始动量误差项、以及噪声项，并且清楚展示了 batch size B 、动量 β 、步长 η 、噪声参数 σ_0, σ_1 怎么进入最终 bound。这个结果是整篇 exact case 的主结论。  MuonNesterov (1)

3. A.1 / A.2 的 sample complexity 结论：从上面的主 bound 继续推出 sample complexity；文中强调当 $\alpha = 2$ 时会退化成 $O(\varepsilon^{-4})$ ，并称这是 optimal。另一个“parameters independent of α ”的设定给出了不显式依赖 α 的参数选法和复杂度结论。这个部分很重要，因为它决定论文的理论卖点是不是“比已有 nonconvex stochastic 优化分析更强”。  MuonNesterov (1)

4. Theorem A.8 / A.14 + Corollary A.16 / A.17：这是 inexact polar 版本真正重要的结果。它们说明，只要近似 polar 误差可以由 δ, ρ 控制，那么 Muon with Nesterov 仍然有收敛保证；而且在 uniformly bounded inexactness 下，sample complexity 的阶数与 exact case 一样，只是常数会变差。这对实际实现非常关键，因为真实训练不会算精确 polar。  MuonNesterov (1)  MuonNesterov (1)

第二层，辅助但很有用的 lemma：

5. Lemma 3.3：说明 mini-batch 后的噪声规模按 $B^{-(\alpha-1)}$ 下降。它不是“最华丽”的 theorem，但对实验最有指导意义，因为它直接预测了“增大 batch 会怎样改善噪声 floor”。  MuonNesterov (1)

6. Lemma 3.4：把 Nesterov 形式改写成一个便于分析的递推

$$\widetilde{M}_k = \beta \widetilde{M}_{k-1} + (1 - \beta)((1 + \beta)G_k - \beta G_{k-1}).$$

这是后面所有误差展开的入口。它本身不是最终结论，但如果你在看 proof structure，它是“钥匙定理”。  MuonNesterov (1)

7. Lemma A.1 / A.6 / A.7：这些是 proof backbone。A.1 是 exact 的 descent inequality，A.6/A.7 是把它推广到 inexact polar。真正的 theorem 基本都是靠这几步拼出来的。

 MuonNesterov (1)

 MuonNesterov (1)

对实验最有指导意义的地方，我觉得有四类。

第一类是 batch size 实验。Lemma 3.3 和后面的主 bound 都在说：batch 越大，噪声项越小，理论上 loss/gradient norm floor 应该更低。因此第四节里提的“固定 oracle budget 看 batch size–loss/accuracy 曲线”是非常对的，这几乎是最直接验证理论趋势的实验。

 MuonNesterov (1)

 MuonNesterov (1)

第二类是 inexact solver / NS iteration 数 q 的实验。Theorem 3.6 说 Newton–Schulz 的近似误差可以用 $\delta_q(M)$ 表示，所以实验上最该做的是：扫 q ，测性能–时间 tradeoff，看少量迭代是否已经足够逼近 exact polar；这直接决定“理论可行”是不是“工程上值得”。第四节里提的 cubic / quintic / polar express 对比，也正是围绕这个点。  MuonNesterov (1)

 MuonNesterov (1)

第三类是 验证 inexact polar assumption 本身。文中明确建议检查 NS 迭代在实验中是否满足

$$\langle M_k, T(M_k) \rangle \approx (1 - \delta_k) \|M_k\|_*, \quad \|T(M_k)\|_{op} \lesssim 1 + \rho_k.$$

这很重要，因为理论成立的前提就是 δ, ρ 小而稳定；如果真实训练里这两个量波动很大，那理论和实践就脱节了。  MuonNesterov (1)  MuonNesterov (1)

第四类是 **Nesterov 相对 vanilla Muon 的收益**。这篇文章的标题和贡献列表都把 “Muon with Nesterov momentum” 当成主角，所以实验里必须清楚回答：它比原始 Muon 到底快多少、稳多少、是否对 batch 或 solver choice 更敏感。这个结论**不是理论自动给出来的**，必须靠实验支撑。  MuonNesterov (1)  MuonNesterov (1)

哪些地方特别需要实验 support，我会直说：

- “Nesterov momentum 让 Muon 更强” 这个主叙事，**必须靠实验**。理论这里只是给了可收敛和复杂度界，不等于说明它在真实训练中优于 Muon / AdamW / Shampoo。  MuonNesterov (1)
- “inexact polar 只影响常数，不影响阶数” 这个结论虽然理论上成立，但在实践里常数可能非常大，所以也**必须靠实验**去看真实 wall-clock 和最终质量。  MuonNesterov (1)
- “randomized / compressed NS 值得用” 也需要实验，因为这类方法的优势通常是更快，但论文主文本里还没有给出真正的经验结果，只是列了计划。  MuonNesterov (1)
- heavy-tailed noise 假设虽然理论上更一般，但是否贴合真实训练噪声，也值得做小规模 empirical check。  MuonNesterov (1)

还有一个我觉得你做汇报时**应该提醒听众**的点：这份稿子里关于 rate / sample complexity 的叙述有点“**两套参数选择并存**”。一处用 $\eta = K^{-1/2}$ 得到 $O(K^{-1/2})$ 型结论，另一处 horizon-dependent 选择 $\beta = 1 - 1/\sqrt{K}, \eta \propto K^{-3/4}$ 给出 $O(K^{-1/4})$ 型结论。它不一定矛盾，但正文需要讲清楚这是**两种 regime**，不然实验很难知道该对齐哪一条理论曲线。

 MuonNesterov (1)  MuonNesterov (1)  MuonNesterov (1)

如果你要拿去讲，我会把它压成一句话：

这篇 paper 的核心不是“发明新 optimizer”，而是“把 Muon + Nesterov + 近似 polar/NS 的理论补齐”，其中最重要的 theorem 是 exact / inexact 两套主收敛界，以及证明 Newton–Schulz 确实满足 inexact polar 假设；而最该做的实验，是 batch size、NS 迭代数/solver choice、以及 Nesterov 相对 vanilla Muon 的真实收益。  MuonNesterov (1)

 MuonNesterov (1)  MuonNesterov (1)  MuonNesterov (1)

如果你愿意，我可以下一条直接帮你整理成一版 **适合组会汇报的 5 分钟中文讲稿**。

这个文档里面的experiment部分很不全。我现在需要写一个 experiment 的 plan，我需要知道有哪些 hyperparameter 或者关键参数是理论可以指导设置的，我要知道有什么实验是我需要做的来 support 理论，比如我需要知道 rank setting, batch size, whether to use newton schulz cubic, qntic, or emprical quitic, or polar express。我需要知道要不要做 randomized vs. not randomized，就是我需要做一些 self-ablation study 来确定一个 default setting，然后跟其它外面的方法对比。但外面的方法我也不太确定有什么方法，我听我的教授说，muon 有用什么 polyyak 的，不确定，做一个实验 plan。

我先把文档里和实验设计直接相关的参数、近似器选择、randomized 设置这些点重新捞一遍，再给你一个能直接执行的实验计划。

我已经把文档里能直接指导实验的参数都定位出来了：batch size、动量/步长的两套 schedule、以及 inexact solver 的 δ, ρ 质量指标。接下来我补外部 baseline，避免你最后只做“自我对比”。

Thought for 2m 39s >

可以，我给你一个能直接写进 paper / proposal 的实验 plan，重点分成三件事：

1. 哪些参数理论能指导设置
2. 哪些实验必须做来 support 理论
3. 怎么先做 self-ablation 定一个 default，再和外部方法比

先说结论：这篇文档里，**理论最能指导的参数**其实不是所有训练超参，而是这几类：batch size B 、动量/步长 (β, η) 、inexact polar solver 的质量参数 (δ, ρ) 、以及 randomized 版本里的 subspace rank / oversampling / power iteration / NS steps。文档自己也已经把实验主线列出来了：randomized vs full-subspace、batch size sweep、验证 inexact polar 假设、以及 solver family 对比。

MuonNesterov (1)

MuonNesterov (1)

1) 理论能指导哪些 hyperparameter

A. Batch size B ：这是最明确、最该扫的

文档里最直接的理论信号就是：mini-batch 后的噪声项会随着 B 增大而下降，量级是 $B^{-(\alpha-1)}$ ；而且主收敛 bound 里还要求 B 足够大，保证像 μ 、 $\Theta_{\delta,\rho}$ 这样的“有效下降系数”为正。也就是说，batch size 不是随便选的，它直接控制 noise floor 和是否进入理论保证区间。 [MuonNesterov \(1\)](#) [MuonNesterov \(1\)](#)

所以实验上你一定要有：

- fixed oracle budget / fixed tokens / fixed steps 下的 batch sweep
- 看 train loss / val loss / accuracy / ppl
- 同时看 wall-clock，因为 batch 大了虽然噪声小，但未必最省时间

这个实验是 paper 里最强的 theory-support 实验之一。文档第四节也明确点名了这一项。

[MuonNesterov \(1\)](#)

B. 动量 β 和步长 η ：理论给“趋势”，实践给 default

这篇稿子里理论对 β, η 给了两套思路：

- 一套是 constant-parameter 分析： β, η 固定；
- 一套是 horizon-dependent 选法： $\beta = 1 - 1/\sqrt{K}$ ， $\eta \propto 1/(\sqrt{d} K^{3/4})$ 一类。

[MuonNesterov \(1\)](#) [MuonNesterov \(1\)](#)

但对真正实验设计来说，更重要的是：bound 里反复出现 $1/(1 - \beta)$ 这种项，所以** β 太接近 1 会放大一些常数项**，不能无脑取特别大。 [MuonNesterov \(1\)](#)

实践上，官方 Muon 仓库给的经验 default 是：

- momentum = 0.95
- nesterov = True
- ns_steps = 5
- 主要只 tune learning rate 和 weight decay。 [GitHub +1](#)

所以我建议你写实验 plan 时这样处理：

- 主实验 default： $\beta = 0.95$, Nesterov = True
- self-ablation： $\beta \in \{0.90, 0.95, 0.98\}$ ，同时比较 Nesterov on/off

这样最合理：既和官方实践对齐，又能回应你这篇 paper 的“with Nesterov”主叙事。官方实现本身也确实是带 Nesterov 的。 [GitHub +1](#)

C. Inexact solver 质量： δ, ρ 是理论真正关心的“近似质量参数”

文档里的 inexact polar 分析，核心不是“你一定要用哪种 solver”，而是说只要近似器 $T(M)$ 满足

- inner product 不太差： $\langle M, T(M) \rangle \geq (1 - \delta) \|M\|_*$
- operator norm 不太膨胀： $\|T(M)\|_{op} \leq 1 + \rho$

那么就还有收敛保证。也就是说，**理论真正关心的是 solver 的 δ, ρ** ，不是 solver 名字本身。  MuonNesterov (1)  MuonNesterov (1)

这意味着：

- cubic NS
- quintic NS
- empirical quintic
- polar express

都可以做，但实验里必须把它们还原成：

1. 下游性能
2. 运行成本
3. 经验上的 $\hat{\delta}, \hat{\rho}$

否则你只是报一个 accuracy，不算 support 理论。

D. NS steps q ：理论明确说“更多步通常更好”，而且可以测

文档对 cubic Newton–Schulz 给出了显式误差衰减形式，误差上界会随着 q 增大快速下降；compressed / randomized 情况下也有类似结论。简单说就是： **q 是强理论相关参数，必须 sweep。**  MuonNesterov (1)  MuonNesterov (1)

所以你至少要做：

- $q \in \{3, 5, 7\}$

如果算力够，再加 $q = 1, 9$ 看更完整曲线。

E. Randomized 版本的 rank / subspace 参数：理论能指导“方向”，不能直接给唯一 default

如果你做 randomized smaller-subspace Newton–Schulz，理论里出现的关键参数是：

- rank k
- oversampling p , 且理论要求 $p \geq 2$
- power iteration h
- 最终子空间维度 $\ell = k + p$  

理论告诉你的是：

- k 越大，子空间丢失项 ξ_Q 越小；
- p 越大，随机 sketch 的误差项更小；
- h 越大， γ_k^{4h} 这个项更小，所以如果谱 gap 不够大，增加 power iteration 会更稳。

 

但理论**没有给一个 universal best rank**。所以 rank setting 不能“拍脑袋一个数”，也不能说理论已经定好了。更准确的写法是：

理论说明更大的子空间、更大的 oversampling、更多 power iterations 会降低 randomized 误差，但最优配置仍需通过 self-ablation 决定。

所以 rank 建议你做成比例 sweep，而不是单点：

- $\ell/r \in \{1/8, 1/4, 1/2, 1\}$
- $p \in \{8, 16\}$
- $h \in \{0, 1, 2\}$

这里 r 我指当前 update matrix 的较小维或 full-subspace 维度。这个比例 sweep 是**实验设计建议**，不是文档直接给出的定理结论。

2) 你必须做哪些实验来 support 理论

我建议你吧理论-support 实验分成 4 组。

实验 1: Batch size 定律

目的：验证理论里 batch size 控制 noise floor / efficiency 的结论。

设计：

- 固定 compute budget / oracle calls / tokens
- sweep B
- 画：
 - final val metric vs batch size
 - training loss vs steps
 - wall-clock vs quality

- 最好再加一个“达到同一 target loss 的总时间 / 总 tokens”

这是最直接支持 Lemma 3.3 和 sample complexity 结论的实验。  MuonNesterov (1)

实验 2：检验 inexact polar 假设是否在真实训练里成立

文档自己明确说要检查 NS iterations 是否满足 inexact polar assumption，连 empirical NS 都建议检查。  MuonNesterov (1)

你应该记录下面两个经验量：

$$\hat{\delta}_k = 1 - \frac{\langle M_k, T(M_k) \rangle}{\|M_k\|_*}, \quad \hat{\rho}_k = \max(0, \|T(M_k)\|_{op} - 1).$$

然后比较：

- cubic
- theoretical quintic
- empirical quintic
- polar express
- randomized vs non-randomized

输出建议：

- 每种 solver 的 $\hat{\delta} / \hat{\rho}$ 均值、分位数
- 随训练步数的曲线
- 与下游 loss / accuracy 的相关性

这组实验非常关键，因为它能把“solver 质量”跟理论里的 (δ, ρ) 真正连起来。

实验 3：randomized vs full-subspace

这个实验文档也明确点名了。  MuonNesterov (1)

目的有两个：

1. 看 randomized 是否显著省算力
2. 看它造成的 subspace loss 是否会显著伤害性能

这组实验里你至少该报：

- 训练吞吐
- orthogonalization 部分耗时占比

- 最终 val metric
- $\hat{\delta}, \hat{\rho}$
- 如果能算，再加 $\hat{\xi}_Q = \|(I - P_Q)M\|_* / \|M\|_*$

如果 randomized 没明显省 wall-clock，或者质量掉很多，就不值得当 default。

实验 4: solver family 比较

文档第四节已经列出：

- NS cubic
- NS quintic (theoretical)
- quintic (empirical)
- polar express。  MuonNesterov (1)

这个实验的目标不是单纯找最好看的一条曲线，而是做一个 **quality-cost Pareto**：

- x 轴：orthogonalization wall-clock / total training wall-clock
- y 轴：最终 val metric 或达到 target metric 所需时间

这样你才能回答：

- “理论最干净”的 solver 是不是实践最好
 - empirical quintic 是否值得当 default
 - polar express 是否只是快，但误差太大
-

3) 我建议的 self-ablation 流程：先定 default，再做大规模对比

你现在最需要的是一个**分阶段**计划，不然参数太多会炸。

Phase A：先在小/中等 proxy task 上定 default

这里的目标不是发结果，是**筛配置**。

A1. 先固定 Muon 主体，选 solver

先固定：

- Nesterov = True
- $\beta = 0.95$
- hidden weights 用 Muon，其他参数用 AdamW

- 先调好一套合理 lr/wd。官方 Muon 也是建议只重点 tune lr 和 wd，而且只把 Muon 用在 hidden weight matrices，上层 head、embedding、bias/gain 用 AdamW。

GitHub +1

然后比较 solver：

- full-subspace cubic
- full-subspace theoretical quintic
- full-subspace empirical quintic
- polar express

每个 solver 只扫：

- $q \in \{3, 5, 7\}$

这个阶段的输出是一个 default solver。

A2. 再决定要不要 randomized

拿 A1 选出的 best solver，再做 randomized vs full：

- $\ell/r \in \{1/8, 1/4, 1/2, 1\}$
- $p \in \{8, 16\}$
- $h \in \{0, 1, 2\}$

输出是一个 default randomized setting，或者你最后决定“主结果还是 full-subspace，randomized 放 ablation”。

Phase B：和 paper 理论直接对齐的 ablation

这里是 support 理论，不一定要全都大规模跑。

最少做这 4 个：

1. batch size sweep
2. Nesterov on/off
3. randomized on/off
4. solver family + q sweep

如果你还有余力，我建议再加：

5. weight decay on/off

原因是外部最新 Muon 理论和 scalable 经验工作都把 “with/without Nesterov” 和 “with/without weight decay” 当成重要 practical variants；而且 2025 年的一篇 Muon 理论

分析就是专门分析了这四种组合，另一篇 [scalable paper](#) 也强调 weight decay 是规模化训练的关键技巧。 [arXiv +2](#)

4) 我建议的 default setting：分“实践默认”和“理论默认”两套写

实践默认（我更推荐你拿它做主结果）

如果你的目标是“先做出强结果，再解释理论”，我建议默认用：

- Nesterov = True
- momentum $\beta = 0.95$
- empirical quintic NS
- ns_steps $q = 5$
- 只 tune lr 和 weight decay
- 只对 hidden weight matrices 用 Muon，其他参数用 AdamW。官方 repo 的默认就是这套方向，代码里用的也是 quintic Newton–Schulz 路线。 [GitHub +2](#)

这套适合拿来做法表，因为比较接近社区实际用法。

理论默认（适合主打 theorem-support）

如果你想“尽量和这篇稿子的 theorem 靠齐”，那可以把：

- full-subspace cubic NS
- Nesterov = True
- $\beta = 0.95$
- $q = 5$

当作你的 theory-aligned default。因为文档里对 cubic NS 的理论最完整、最干净。

最好的写法是：**主结果用实践默认，附加一组 theory-aligned 默认**。这样 reviewers 会觉得你既尊重实践，也尊重理论。

5) 外部 baseline 怎么选

你不用把 baseline 搞得太多。一个**最小但可信**的对比集合可以是：

必选

- AdamW：Muon's official repo 和后续 scalable work 都把 AdamW 当核心比较对象。

- **Original / official Muon default:** 也就是官方默认那套 practical Muon。这样你才能回答“你的 Nesterov-analysis paper 对实际 Muon 设置有没有帮助”。 GitHub +1
- Shampoo
- SOAP

因为官方 Muon README 明确提到过 AdamW、Shampoo、SOAP 的 benchmark。

GitHub +1

可选

- SGD + Polyak momentum
- SGD + Nesterov momentum

你教授说的 “polyak” 我倾向于理解成 heavy-ball / Polyak momentum baseline，而不是说 “Muon 默认就是 Polyak”。官方 Muon 的实践默认其实是 `Nesterov=True`。所以如果你要放 Polyak，更适合当经典动量基线，不是 Muon 家族主 baseline。 GitHub +1

我不建议一开始就放太多的

不建议一上来再加 Lion、Adafactor 一堆方法，不然你实验矩阵太大，主线会散。

6) 一个可以直接执行的实验矩阵

Part I: default-setting (小规模, 快速)

目标：选 default，不追求最终最好数值

- Solver:
 - cubic
 - theoretical quintic
 - empirical quintic
 - polar express
- NS steps:
 - 3, 5, 7
- Nesterov:
 - on / off
- β :
 - 0.90 / 0.95 / 0.98
- Randomized:
 - off
 - on with $\ell/r \in \{1/8, 1/4, 1/2\}$, $p \in \{8, 16\}$, $h \in \{0, 1\}$

输出：

- 选一个practical default
 - 选一个theory default
-

Part II: theory-support (中规模)

目标：给 theorem 找实证支撑

1. Batch size sweep
2. 验证 $\hat{\delta}, \hat{\rho}$
3. randomized vs non-randomized
4. solver family + q
5. (可选) weight decay on/off

输出：

- batch-quality-time 曲线
 - $\hat{\delta}, \hat{\rho}$ 统计
 - randomized 的速度/精度 tradeoff
-

Part III: external comparison (中/大规模)

目标：主表

默认只比：

- AdamW
- Shampoo
- SOAP
- official Muon default
- your Muon+Nesterov default

如果老师 insist，再加：

- SGD+Polyak
 - SGD+Nesterov
-

7) 写在 paper 里的核心叙述建议

你可以把实验 section 的逻辑写成这样：

We first perform self-ablation to determine a practical default configuration for Muon with Nesterov momentum, including the choice of inexact polar solver, the number of Newton–Schulz steps, and whether to use randomized subspace compression. We then conduct theory-oriented experiments to validate the predicted role of batch size and the inexact-polar quality parameters. Finally, we compare the resulting default configuration against external baselines including AdamW, Shampoo, SOAP, and the official Muon implementation.

这段逻辑是顺的，而且不会让 reviewer 觉得你只是乱 sweep 参数。

8) 我给你的最终建议

最实用的一版是：

- **主结果 default**：Nesterov=True, $\beta = 0.95$, empirical quintic, $q = 5$, hidden weights 用 Muon，其他参数用 AdamW。 GitHub +1
- **一定要做的 theory-support**：batch size、 $\hat{\delta}/\hat{\rho}$ 、randomized vs full、solver family。
- **rank setting 不要只报一个数**：先用比例 sweep 定 default，因为理论只告诉你“大一点更稳”，没给 universal 最优 rank。
- **外部 baseline 最少要有**：AdamW、official Muon、Shampoo、SOAP；Polyak 可以做可选经典基线，但不是必须主角。 GitHub +2

下一条我可以直接帮你把这个整理成一个论文里可直接贴的“Experiments Plan”小节草稿。

Sources

     ...  Sources

Theorem 3.6和theorem B.5什么关系

我去把这两个 theorem 的原文抓成可引用的片段，然后直接讲它们的层级关系。

Thought for 56s >

它们的关系很直接：

Theorem 3.6 是 full / non-randomized 版本，Theorem B.5 是它的 compressed / randomized 扩展版。  MuonNesterov (1)

更具体地说：

1. Theorem 3.6 讲的是什么

Theorem 3.6 研究的是：直接在原矩阵 M 上做 normalized cubic Newton–Schulz，

$$X_0 = M/\alpha, \quad X_{t+1} = \frac{3}{2}X_t - \frac{1}{2}X_t X_t^\top X_t,$$

然后定义 $T_q(M) = X_q$ 。它证明这个 $T_q(M)$ 满足 inexact polar 的假设，而且给出精确参数

$$\rho_q(M) = 0, \quad \delta_q(M) = 1 - \frac{\sum_i \sigma_i p_q(s_i)}{\sum_i \sigma_i}.$$

也就是说，这里只有一种误差来源：Newton–Schulz 本身还没收敛完。

 MuonNesterov (1)

2. Theorem B.5 多了什么

Theorem B.5 先取一个子空间 Q ，把矩阵压缩成

$$B = Q^\top M,$$

然后在压缩后的 B 上做 Newton–Schulz，得到 Z_q ，最后 lift 回原空间：

$$T_{Q,q}(M) = QZ_q.$$

它证明这个 compressed 版本也满足同样的 inexact polar 条件。  MuonNesterov (1)

但这时候误差不再只有一种，而是分成两部分：

- subspace loss：因为你先投影到 Q ，丢了一部分信息；
- compressed matrix 上的 NS loss：因为在 B 上做的 NS 也还没完全收敛。

它把总误差精确分解成

$$\delta_{Q,q}^*(M) = 1 - (1 - \xi_Q^*(M))(1 - \delta_q^{NS}(B)),$$

其中

$$\xi_Q^*(M) = 1 - \frac{\|P_Q M\|_*}{\|M\|_*}$$

是子空间压缩损失，

$$\delta_q^{NS}(B) = 1 - \frac{\sum_i \hat{\sigma}_i p_q(\hat{s}_i)}{\sum_i \hat{\sigma}_i}$$

是压缩矩阵上的 NS 误差。而且依然有 $\rho = 0$ 。  MuonNesterov (1)

3. 所以两者的层级关系是

你可以把它理解成：

- Theorem 3.6：先回答
“如果我不做随机化、不做压缩，直接在 M 上跑 cubic NS，会得到多好的 inexact polar oracle？”
- Theorem B.5：再回答
“如果我先随机/压缩到子空间，再在小矩阵上跑 cubic NS，再 lift 回来，会得到多好的 oracle？”

所以 B.5 = 3.6 + 子空间压缩这一层。  MuonNesterov (1)

4. 3.6 是 B.5 的特例

如果你在 B.5 里取 full subspace，也就是 $Q = I$ ，那么

- $B = Q^\top M = M$
- $P_Q = I$
- $\xi_Q^*(M) = 0$

于是 B.5 里的公式就变成

$$\delta_{Q,q}^*(M) = 1 - (1 - 0)(1 - \delta_q^{NS}(M)) = \delta_q^{NS}(M),$$

这正好就是 Theorem 3.6 的 $\delta_q(M)$ 。同时 $\rho = 0$ 也一致。

所以可以直接说：

Theorem 3.6 是 Theorem B.5 在 $Q = I$ （不压缩、不随机化）时的特例。

 MuonNesterov (1)

5. 对实验设计的意义

这两个 theorem 对你的实验 plan 影响很大：

- 3.6 支持你做 **full-subspace cubic NS**；
- B.5 支持你做 **randomized vs non-randomized**，而且告诉你 randomized 版本为什么会变差：

不是只有 NS step 数 q 的问题，还多了一个 **rank / subspace choice** 带来的 ξ_Q 项。

 MuonNesterov (1)

所以你做 ablation 时可以很自然地写成：

- 固定 q ，比较 randomized vs full，测的是 **subspace loss**
- 固定 rank / Q ，比较不同 q ，测的是 **NS approximation loss**

这正好对应 B.5 里的两部分误差分解。  MuonNesterov (1)

一句话版：

Theorem 3.6 只分析“直接在 M 上做 cubic NS”的误差；Theorem B.5 分析“先压缩到子空间，再在压缩矩阵上做 cubic NS”的误差，并把总误差分解成“子空间损失 + NS 误差”。所以 B.5 是 3.6 的 randomized / compressed generalization，而 3.6 是 B.5 的 full-rank special case。  MuonNesterov (1)

如果你想，我下一条可以直接帮你把这两个 theorem 画成一个 proof map / relation diagram，方便你写 related theory 或 experiment motivation。

Sources



MuonNesterov (1)(1).pdf
PDF

我要看的是randomized的版本，重新说哪些theorem是重要的，对实验有指导意义，或者需要实验support的

我把 randomized 这条线重新收束成一条链：“**压缩子空间质量** → **压缩后 polar 近似质量** → **最终优化收敛**”。这样你写实验时就知道每个 theorem 对应哪类 ablation。

Thought for 21s >

如果你现在**只看 randomized version**，那最重要的 theorem 不再是单独的 Theorem 3.6，而是下面这条链：

B.5 / B.6 / B.7 / B.9 负责说明 randomized compressed solver 本身有多好；A.11 / A.14 / A.16 / A.17 负责说明只要这个 solver 满足 (δ, ρ) 条件，Muon with Nesterov 就会怎么收敛。 也就是说，randomized 版本的实验主线应该围绕：

子空间压缩误差 ξ_Q 、压缩后 solver 误差 (δ_B, ρ_B) 、以及它们合成后的整体 inexactness (δ, ρ) 。  MuonNesterov (1)

一、randomized 版本里最重要的 theorem

1. Theorem B.5：最核心

这是 randomized version 最重要的 theorem。

它研究的是：先取一个子空间 Q ，压缩成

$$B = Q^\top M,$$

然后在压缩后的 B 上做 cubic Newton–Schulz，最后 lift 回原空间：

$$T_{Q,q}(M) = QZ_q.$$

它最重要的地方不是“又证明了一次 NS”，而是给了你一个**误差分解**：

$$\delta_{Q,q}^*(M) = 1 - (1 - \xi_Q^*(M))(1 - \delta_q^{NS}(B)).$$

也就是 randomized 的总误差来自两部分：

- **subspace loss**： ξ_Q ，因为你只在子空间里做；
- **compressed matrix 上的 NS loss**： $\delta_q^{NS}(B)$ ，因为 NS 步数有限。  MuonNesterov (1)

这个 theorem 对实验最有指导意义，因为它直接告诉你 randomized ablation 应该拆成两类：

- 固定 solver，扫 rank / subspace 质量
- 固定 rank，扫 NS steps / solver family

它还告诉你一个特别重要的结论：对 cubic compressed NS，有

$$\rho_{Q,q}(M) = 0,$$

所以 randomized cubic 的问题主要不是 norm inflation，而是 **progress 不够，也就是 δ 变大**。  MuonNesterov (1)

实验含义：

- randomized vs non-randomized 必做
- rank / subspace dimension 必扫
- NS steps q 必扫
- 如果 randomized 掉点，要区分到底是 ξ_Q 大，还是压缩后 NS 不够准

2. Corollary B.6：最直接指导 rank / oversampling / power iteration

如果你真打算实现 randomized subspace iteration，

$$Y = (MM^\top)^h M\Omega, \quad Q = \text{orth}(Y),$$

那最直接有实验指导意义的是 Corollary B.6。  MuonNesterov (1)

它把 randomized 的质量进一步写成依赖这些参数的形式：

- rank k
- oversampling p
- power iteration h
- 谱 gap $\gamma_k = \sigma_{k+1} / \sigma_k$

并说明总误差受这些量控制。最关键的趋势是：

- k 越大，subspace loss 越小；
- p 越大，随机 sketch 更稳；
- h 越大， γ_k^{2h} 或更高次项更小，所以谱分离不强时，power iteration 更重要。

 MuonNesterov (1)

实验含义：

这是最能指导 rank setting 的 theorem。它没有给你唯一的最佳 rank，但明确说明你该扫哪些轴：

- subspace dimension / rank
- oversampling
- power iteration

所以 randomized 版本里，rank setting 不是一个“实现细节”，而是主实验参数。

3. Theorem B.7: 你比较 cubic / quintic / empirical quintic / polar express 的总框架

B.7 是 randomized 部分第二个非常重要的 theorem，因为它不是只针对 cubic NS，而是一个 lifting theorem：

只要你有任意一个 compressed solver $S(B)$ ，然后 lift 成

$$T(M) = Q S(Q^\top M),$$

那么它的整体误差满足

$$\delta(M) = 1 - (1 - \xi_Q(M))(1 - \delta_B), \quad \rho(M) = \rho_B.$$

📄 MuonNesterov (1)

这一定理的意义非常大：

它告诉你 randomized 版本下，所有 solver family 的比较都应该统一成同一个框架：

- 子空间损失 ξ_Q
- 压缩 solver 自身误差 (δ_B, ρ_B)

所以你后面想比较：

- cubic
- theoretical quintic
- empirical quintic
- polar express

都应该按 B.7 的逻辑来解释，而不是只报最后 accuracy。 📄 MuonNesterov (1)

实验含义：

solver comparison 必须做，而且要测：

- 整体下游效果
 - compressed solver 的经验 $\hat{\delta}_B, \hat{\rho}_B$
 - 最终 lift 后的经验 $\hat{\delta}, \hat{\rho}$
-

4. randomized subspace + cubic / quintic corollaries: 最直接支持 solver-family 实验

B.7 后面其实已经把你最关心的 randomized solver family 给展开了。

对于 randomized + cubic NS, 文中给出:

- $\rho = 0$
- δ 由 ξ_Q 和 q 共同决定。  MuonNesterov (1)

对于 randomized + quintic NS, 文中给出:

- $\delta = \xi_Q + (1 - \xi_Q)\varepsilon_B$
- $\rho = \varepsilon_B$

也就是说 quintic 的代价是可能有一些 operator norm inflation, 但近似速度更快。

 MuonNesterov (1)

实验含义:

这直接告诉你:

- cubic vs quintic 不是简单的“谁更准”
- cubic 更偏向 $\rho = 0$ 的干净理论
- quintic 可能更快更准, 但要付出 $\rho > 0$ 的代价

所以比较它们时, 必须同时看:

- 质量
- 速度
- $\hat{\delta}, \hat{\rho}$

这正是 randomized solver-family ablation 的理论理由。  MuonNesterov (1)

5. Theorem B.9: 最有“可解释性”的 randomized theorem

如果你想把 randomized 版本写得更“像一个理论 paper”, B.9 很重要。

它针对 Gaussian randomized subspace + cubic NS, 给了一个**显式的** expected progress bound, 把效果直接写成 k, p, h 和谱结构的函数。特别是它给出了一个不带随机量的显式 $\bar{\delta}_{h,q}(M)$ 上界。  MuonNesterov (1)

这一定理对实验的价值是:

- 你可以理直气壮地把 randomized 参数 sweep 写成:
 - rank k

- oversampling p
- power iter h
- 因为理论已经说了这几个量决定 expected progress

实验含义：

B.9 最支持做：

- k sweep
- p sweep
- h sweep
- 看谱 gap 大小不同的层 / 模型上 randomized 的表现差异

如果你愿意做更深一点，还可以分析：**谱 gap 大的层是不是更适合 aggressive compression。**  MuonNesterov (1)

二、哪些 theorem 对“最终优化实验”最重要

上面那几个 theorem 告诉你 randomized solver 本身有多好，但还没告诉你 Muon 训练会怎样。这里就要接回 A 部分。

6. Assumption 3.5 / A.9：整个 randomized 实验的接口

这两个 assumption 是 randomized solver 和优化理论的接口：

$$\mathbb{E}[\langle M_k, T(M_k) \rangle | M_k] \geq (1 - \delta_k) \|M_k\|_*, \quad \mathbb{E}[\|T(M_k)\|_{op}^2 | M_k] \leq (1 + \rho_k)^2.$$

你 randomized solver 的所有实验，最终都应该落到“它经验上是不是满足这两条”。

 MuonNesterov (1)

实验含义：

必须测经验版

$$\hat{\delta}_k, \hat{\rho}_k.$$

这不是可做可不做，而是 randomized 理论最需要 support 的实验。

7. Lemma 3.3 / A.10：batch size 仍然很重要

虽然你现在关注 randomized，但 batch size 的噪声项并没有消失。文档明确说 mini-batch noise 仍然按 $B^{-(\alpha-1)}$ 降。  MuonNesterov (1)

所以 randomized 版本里，batch size 仍然是理论指导最强的外部训练参数之一。

实验含义：

即使主角是 randomized，你也还要做：

- fixed compute 下 batch sweep

因为 batch 影响的是 stochastic noise，而 rank / q / solver 影响的是 inexact polar 质量，这两类误差是不同来源。

8. Theorem A.14: randomized solver 最终如何影响优化收敛

A.14 是 randomized / inexact 版本最终优化结论最重要的 theorem。

它说明如果你的 inexact oracle 满足统一上界 $\bar{\delta}, \bar{\rho}$ ，那么平均梯度范数满足一个 bound，关键项里出现

$$\Theta_{\delta, \rho} = (1 - \bar{\delta}) - A_{\rho} \frac{\kappa_{\alpha} \sigma_1}{B^{(\alpha-1)/\alpha}}.$$

 MuonNesterov (1)

这个式子对实验特别有指导意义，因为它说：

- $\bar{\delta}$ 大，会直接削弱下降
- $\bar{\rho}$ 大，会放大常数项
- B 太小，也会让有效下降系数变差

也就是说 randomized 实验里，你不能只看 rank，也不能只看 solver。理论上真正的 tradeoff 是：

compression / approximation error vs stochastic noise。

实验含义：

你该设计“二维 sweep”而不是单 sweep：

- batch size $B \times \text{rank}$
 - batch size $B \times q$
 - rank $\times$ solver family
-

9. Corollary A.16 / A.17: 告诉你怎么组织 fixed-parameter 和 horizon-dependent 实验

A.16 说：如果 $\bar{\delta}, \bar{\rho}$ 被控制住，且 B 足够大，那么 fixed- β 、 $\eta = K^{-1/2}$ 时有

$$O(K^{-1/2}) + O(B^{-(\alpha-1)/\alpha})$$

型的结果。A.17 则给 horizon-dependent 参数下另一类 rate。  MuonNesterov (1)

实验含义：

你至少应该有两类设定中的一种：

- **practical fixed-parameter setting**：更像真实训练
- **theory-aligned horizon-dependent setting**：更像 theorem support

如果篇幅有限，我建议主实验用 fixed-parameter，附录里做一个 theory-aligned 小实验。

三、对 randomized 版本最有指导意义的实验

如果按 theorem 来倒推，我建议 randomized 版本实验至少分 5 组。

实验 1：randomized vs non-randomized

这是必须做的，因为 B.5 的核心就是把 total error 分成 subspace loss + NS loss。

 MuonNesterov (1)

看什么：

- 最终 val metric
- train loss
- wall-clock
- orthogonalization 时间占比
- $\hat{\delta}, \hat{\rho}$

目的：

- 看 randomized 是否真的值得
- 看它掉点主要是不是来自 ξ_Q

实验 2：rank / subspace dimension sweep

这是 randomized 版本最关键的 self-ablation，因为 B.5/B.6/B.9 都在告诉你 **rank 是主参数**。  MuonNesterov (1)

建议：

- 子空间比例 $\ell/r \in \{1/8, 1/4, 1/2, 1\}$
- 或直接固定几个 rank 档位

看什么：

- quality
 - speed
 - $\hat{\delta}$
 - 如能算，再看经验 $\hat{\xi}_Q$
-

实验 3：power iteration h 和 oversampling p

如果你用 randomized subspace iteration，就别只扫 rank，不扫 h, p 会很可惜，因为 B.6/B.9 明确说明它们影响子空间质量。  MuonNesterov (1)

建议：

- $h \in \{0, 1, 2\}$
- $p \in \{8, 16\}$ 或 $\{4, 8, 16\}$

目的：

- 确定 default randomized sketch setting
 - 看加一点 power iteration 是否比单纯提 rank 更划算
-

实验 4：solver family $\times$ NS steps

这是 B.7 直接支持的实验。  MuonNesterov (1)

比较：

- randomized cubic
- randomized theoretical quintic
- randomized empirical quintic
- randomized polar express

每个 solver 再扫：

- $q \in \{3, 5, 7\}$

看：

- 最终性能
- 速度

- $\hat{\delta}, \hat{\rho}$

这个实验用来回答：

- default 应该选哪一个 solver
- cubic 的干净理论值不值得牺牲实践性能
- quintic / empirical quintic 是否是更好的实际默认值

实验 5：验证 inexact polar assumption

这个实验对 randomized 尤其重要，因为 randomized 比 full 多了一个 subspace loss 来源。文档第四节自己也把这项列出来了。 [MuonNesterov \(1\)](#)

记录：

$$\hat{\delta}_k = 1 - \frac{\langle M_k, T(M_k) \rangle}{\|M_k\|_*}, \quad \hat{\rho}_k = \max(0, \|T(M_k)\|_{op} - 1).$$

最好报：

- 不同 solver / rank / q 下的均值、中位数、95 分位数
- 随训练过程的变化

这项实验是 randomized 理论最直接的 empirical support。

四、哪些地方最需要实验 support

如果你只看 randomized 版本，我觉得最需要实验支持的是这几句“理论外推”：

1. randomized 是否真的值得

理论说 randomized 会引入 ξ_Q ，但换来更便宜的压缩计算。到底值不值，**完全要靠实验**。

B.5/B.6 只能告诉你误差怎么分解，不能告诉你 wall-clock 上是否胜出。 [MuonNesterov \(1\)](#)

2. best default rank / h / p 是什么

理论只告诉你“大一点更稳”“多一点 power iter 更稳”，但并没有给 universal 最优 default。

这个一定要靠 self-ablation。 [MuonNesterov \(1\)](#)

3. cubic vs quintic vs empirical quintic vs polar express

B.7 只给了统一 lifting 框架，不会替你决定哪个是实践最优。这个是最典型的“理论给指标，实验给 default”。 [MuonNesterov \(1\)](#)

4. 理论里的 δ, ρ 在真实训练中是不是稳定

尤其 randomized 下， ξ_Q 和 ℓ_B 都会随层、随步数变化。理论里很多结论是假设它们被控制住，真实训练里是否如此，需要实验 support。  MuonNesterov (1)

五、如果你现在只想抓“最重要的 theorem”

我会这么排序：

第一梯队：必须讲

- Theorem B.5: randomized compressed cubic NS 的总误差分解
- Theorem B.7: general compressed solver 的 lifting theorem
- Theorem A.14: 把 randomized / inexact solver 的 (δ, ρ) 接到最终优化收敛上。

 MuonNesterov (1)

第二梯队：强实验指导

- Corollary B.6: rank / oversampling / power iteration 怎么影响 randomized 质量
- Theorem B.9: Gaussian randomized subspace + cubic 的 expected bound
- Corollary A.16 / A.17: fixed-parameter 和 horizon-dependent 两种训练设定怎么组织。

 MuonNesterov (1)

第三梯队：支撑性

- Assumption 3.5 / A.9: 实验里要测的 $\hat{\delta}, \hat{\rho}$ 从哪来
- Lemma 3.3 / A.10: batch size 为什么仍然要扫。

 MuonNesterov (1)

六、一句话总结成实验主线

如果你写 randomized experiments，我建议主线直接写成：

We study randomized compressed Muon through three coupled factors: subspace quality, compressed polar-solver quality, and downstream optimization performance. Guided by Theorems B.5 and B.7, we decompose the approximation error into a subspace loss term and a compressed-solver term; guided by Theorem A.14, we then evaluate how these errors interact with stochastic optimization through batch size and training horizon.

这个逻辑和你的理论部分是完全对齐的。  MuonNesterov (1)

如果你愿意，我下一条可以直接把这套内容整理成一个**“Randomized Experiments” 小节草稿**，按 paper 写法列成 subsection 和表格。

Sources



Theorem B.9需要實驗嗎

Thought for 11s

要分两层说：

严格来说，Theorem B.9 作为数学定理，本身不需要实验来“证明”。

但如果你打算在 paper 里把它当成 **randomized 方法有实践指导意义** 的核心卖点之一，那我认为**需要配实验 support**，不过不需要那种“逐项精确验证公式常数”的重实验。

MuonNesterov (1)

为什么说它“需要一些实验 support”

B.9 讲的是 **Gaussian randomized subspace + cubic Newton–Schulz** 的 expected inexact-polar 保证。它明确把 randomized 质量写成和这些量有关：

- rank k
- oversampling p
- power iteration h
- 谱 gap $\gamma_k = \sigma_{k+1} / \sigma_k$

并给出 expected progress bound / 显式的 $\bar{\delta}_{h,q}(M)$ 上界。也就是说，它不是纯存在性结果，而是在说：

这些 randomized 参数会系统性影响近似质量。 MuonNesterov (1)

只要你在正文里想说：

- randomized setting 是有理论支撑的；
- rank / p / h 的选择有理论依据；
- Gaussian sketch 的设计不是拍脑袋；

那就最好有实验来展示这些**趋势确实在真实训练里能看到**。 MuonNesterov (1)

但它不需要“重度”实验

我不建议你为了 B.9 去做那种特别硬核的“精确拟合 theorem 上界”的实验，因为：

1. B.9 里很多量和矩阵谱有关，真实训练里逐步精确估它们会很贵。
2. 这类 theorem 更适合支持**趋势**，不适合要求实验逐点 match 常数。
3. 你的 paper 主线更可能是“randomized Muon 实际是否好用”，不是“B.9 上界是否 tight”。

所以 B.9 更适合配 qualitative / semi-quantitative support，而不是 full verification。

📄 MuonNesterov (1)

最少应该做哪些实验来 support B.9

如果 B.9 保留在 paper 里，我建议至少做下面两类：

1. randomized 参数 sweep

因为 B.9 直接依赖 k, p, h ，所以最自然的 support 就是：

- sweep rank k 或子空间维度
- sweep oversampling p
- sweep power iteration h

然后看：

- 最终 val metric / loss
- wall-clock
- 经验 $\hat{\delta}$

如果趋势是：

- k 大一些更稳
- p 大一些更稳
- h 增加在某些情形下有帮助

那就已经是对 B.9 很好的 support 了。 📄 MuonNesterov (1)

2. 经验 progress / inexactness 验证

B.9 讲的是 expected inexact-polar quality，所以你最好记录：

$$\hat{\delta}_k = 1 - \frac{\langle M_k, T(M_k) \rangle}{\|M_k\|_*}$$

再看不同 k, p, h 下它怎么变。

这比只报最终 accuracy 更贴 B.9 的内容。 📄 MuonNesterov (1)

哪种情况下可以不专门为 B.9 做实验

如果你在文章里把 B.9 只放在：

- appendix
- supporting theory
- “说明 Gaussian randomized setting 也有显式理论”

而**不把它当 main empirical claim**，那你可以不单独为 B.9 设计一整组实验。

这时只要你的 randomized 主实验里已经包含：

- randomized vs full
- rank sweep
- maybe h / p sweep

其实就已经间接 support B.9 了。  MuonNesterov (1)

我的建议

我会这样处理：

- B.5 / B.7 / A.14 是主理论，必须有明确实验 support。
- B.9 是更细的 randomized-Gaussian 理论，**建议有 support，但不用单开一个“大 theorem verification”实验。**
- 最实际的做法是：把 rank / p / h sweep 放进 randomized ablation，然后在文字里说“these trends are consistent with Theorem B.9”。

一句话说：

B.9 不需要被“专门证明式实验验证”，但如果它被用来支持你对 Gaussian randomized setting 的参数设计和实践价值，就应该至少有一组 k, p, h 的 ablation 来对应它。

 MuonNesterov (1)

如果你愿意，我下一条可以直接帮你判断：B.9 在你的 paper 里应该放 main text 还是 appendix。

Sources



写一版实验设计plan，记住写清楚具体计算方式，具体 check 什么东西，check 的这个东西是什么。把每个实验用

来check什么assumption或者theorem写出来，具体那个check的东西是什么，画什么图，什么的写清楚。中文写

我先把理论和实验接口重新对齐一下：重点会围绕 randomized 版本，把每个实验对应到具体 theorem / assumption，并把要计算的量、画的图、判定标准都写成可执行的方案。

我会把方案分成“参数筛选、理论验证、主结果对比”三层，并按“实验目标—计算量—图—对应 theorem / assumption”的格式写。重点会围绕三类量：子空间误差 ξ_Q 、压缩后 solver 误差 (δ_B, ρ_B) 、以及 lift 后整体误差 (δ, ρ) 。

Thought for 21m 37s >

下面给你一版面向 randomized version 的中文实验设计 plan。我按“统一记号与计算量 → 理论支持实验 → 端到端性能实验 → 默认设置选择规则”来写，而且每个实验我都写清楚：

- 要 check 什么东西
- 这个东西是什么
- 具体怎么计算
- 对应哪个 assumption / theorem
- 画什么图
- 这个实验最后用来做什么决策

这版 plan 的核心逻辑是：

B.5 / B.7 / B.9 负责说明 randomized compressed solver 的质量；A.9 / A.14 / A.16 / A.17 负责说明这种 inexact solver 会如何影响最终优化；文档第 4 节自己也明确建议做 randomized vs full、batch size、inexact polar assumption 检查、以及 solver family 对比。

 MuonNesterov (1)

 MuonNesterov (1)

 MuonNesterov (1)

 MuonNesterov (1)

0. 总体设计原则

我建议把实验分成两层。

第一层：theorem-support 的代理实验（proxy experiments）

目的不是追最终最好指标，而是要**精确计算**定理里的量，比如 ξ_Q 、 δ_B 、 ρ_B 、 ℓ_B 、 γ_k 、 $\bar{\delta}_{h,q}$ 等。这类实验最好在**较小模型或抽样层**上做，因为需要 exact SVD / exact polar。
做法建议：

- 用主模型的缩小版（比如 1/4 或 1/8 规模）

- 每隔固定 step（比如每 200 或 500 step）保存一次若干层的 M_k
- 只抽样 4 个代表层：浅层 attention、浅层 MLP、中层 attention、深层 MLP
- 对这些快照离线做 exact SVD 和 exact polar

第二层：端到端性能实验（main experiments）

目的是真正回答 randomized Muon with Nesterov 值不值得用，以及 default setting 是什么。这里不需要每一步都算 exact SVD，只需要用第一层挑出来的 default 跑完整训练。

📄 MuonNesterov (1)

1. 统一记号与统一记录的量

先把所有实验里都要记录的量定义清楚。为了避免混淆，我把 mini-batch size 记成 B_{batch} ，而把 theorem 里的压缩矩阵继续记成

$$B = Q^\top M.$$

1.1 每次诊断时要保存的对象

在某个 step、某一层，保存：

$$M \in \mathbb{R}^{d \times d}, \quad Q \in \mathbb{R}^{d \times \ell}, \quad P_Q = QQ^\top, \quad B = Q^\top M \in \mathbb{R}^{\ell \times d}.$$

其中：

- M ：Muon 做 polar / inexact polar 之前的矩阵
- Q ：randomized subspace basis
- $B = Q^\top M$ ：压缩后的矩阵
- $S(B)$ ：压缩矩阵上的 solver 输出
- $T(M) = QS(B)$ ：lift 回原空间后的最终方向

对 exact 参考量，用 SVD 计算：

$$\begin{aligned} M &= U \Sigma V^\top, & O(M) &= UV^\top, \\ B &= U_B \Sigma_B V_B^\top, & O(B) &= U_B V_B^\top. \end{aligned}$$

同时统一使用：

$$\langle A, B \rangle = \text{tr}(A^\top B), \quad \|A\|_* = \sum_i \sigma_i(A), \quad \|A\|_{op} = \sigma_1(A).$$

这些定义正对应文档里 inexact polar 的 (A1)–(A2)、B.5 的 compressed NS、B.7 的 lifting framework、以及 B.9 的 Gaussian randomized subspace 设定。 📄 MuonNesterov (1)

1.2 全部实验统一要算的诊断量

(a) 全空间的 inexactness 量

$$r_{\text{full}} := \frac{\langle M, T(M) \rangle}{\|M\|_*}, \quad \hat{\delta} := 1 - r_{\text{full}}.$$

它的意义是：最终 lifted 方向和 M 的对齐程度。

$\hat{\delta}$ 越小越好。

$$u_{\text{full}} := \|T(M)\|_{op}, \quad \hat{\rho} := \max(0, u_{\text{full}} - 1).$$

它的意义是：最终 lifted 方向有没有发生 operator norm inflation。

$\hat{\rho}$ 越小越好。

这两个量直接对应 Assumption 3.5 / A.9 的

$$\langle M, T(M) \rangle \geq (1 - \delta) \|M\|_*, \quad \|T(M)\|_{op} \leq 1 + \rho.$$

(b) 压缩 solver 自身的误差

$$r_B := \frac{\langle B, S(B) \rangle}{\|B\|_*}, \quad \hat{\delta}_B := 1 - r_B,$$

$$u_B := \|S(B)\|_{op}, \quad \hat{\rho}_B := \max(0, u_B - 1).$$

它们的意义是：只看压缩矩阵上的 solver 本身有多准。

B.7 里这正是 compressed solver 的质量参数 (δ_B, ρ_B) 。 MuonNesterov (1)

(c) 子空间损失

$$\Gamma_Q := \frac{\|P_Q M\|_*}{\|M\|_*}, \quad \xi_Q := 1 - \Gamma_Q.$$

它的意义是：你只在 Q 这个子空间里做近似时，丢掉了多少信息。

ξ_Q 越小，说明 randomized 压缩造成的损失越小。

这正是 B.5 / B.7 里最重要的“subspace-loss fraction”。

(d) B.5 / B.7 的分解残差

对 cubic NS, B.5 给出

$$\delta_{Q,q}(M) = 1 - (1 - \xi_Q)(1 - \delta_{NS}(B)).$$

因此实验里定义

$$e_{\delta}^{B.5} = \left| \hat{\delta} - (1 - (1 - \xi_Q)(1 - \hat{\delta}_B)) \right|.$$

对一般 solver, B.7 给出

$$\delta(M) = 1 - (1 - \xi_Q)(1 - \delta_B), \quad \rho(M) = \rho_B,$$

因此定义

$$e_{\delta}^{B.7} = \left| \hat{\delta} - (1 - (1 - \xi_Q)(1 - \hat{\delta}_B)) \right|, \quad e_{\rho}^{B.7} = |\hat{\rho} - \hat{\rho}_B|.$$

这两个残差越小, 说明 theorem 的 lifting / factorization 越贴合真实实现。

☐ MuonNesterov (1)

☐ MuonNesterov (1)

(e) 用于 cubic / quintic 理论上界的量

定义

$$\ell_B := \frac{\sigma_{\min}^+(B)}{\alpha_B},$$

其中 α_B 是压缩矩阵做 NS 时的 normalization 常数。

对 randomized + cubic, 文档给出

$$\delta_{Q,q}^{(3)}(M) \leq \xi_Q + (1 - \xi_Q)(1 - \ell_B^2)^{2^q}, \quad \rho_{Q,q}^{(3)}(M) = 0.$$

对 randomized + quintic, 文档给出

$$\varepsilon_B = (1 - \ell_B)^{2^q},$$

$$\delta_{Q,q}^{(5)}(M) = \xi_Q + (1 - \xi_Q)\varepsilon_B, \quad \rho_{Q,q}^{(5)}(M) = \varepsilon_B.$$

因此实验里可以计算:

$$u_{\delta}^{(3)} = \xi_Q + (1 - \xi_Q)(1 - \ell_B^2)^{2^q},$$

$$u_{\delta}^{(5)} = \xi_Q + (1 - \xi_Q)(1 - \ell_B)^{2^q}, \quad u_{\rho}^{(5)} = (1 - \ell_B)^{2^q}.$$

然后检查 empirical $\hat{\delta}, \hat{\rho}$ 是否落在这些理论上界之下。

☐ MuonNesterov (1)

(f) B.9 用到的谱量

对于 Gaussian randomized subspace iteration, 定义

$$\gamma_k := \frac{\sigma_{k+1}(M)}{\sigma_k(M)}.$$

它的意义是: 第 k 个奇异值处的谱 gap。

γ_k 越小, 说明 top- k 子空间越容易被 sketch 抓住。

B.9 的显式 expected progress 下界对应的归一化版本可以写成

$$r_{\text{B9}}^{\text{lb}}(M; k, p, h) = \frac{1}{\sigma_1(M) \|M\|_*} \left[\sum_{j=1}^k \sigma_j^2 - \frac{k}{p-1} \gamma_k^{4h} \sum_{j>k} \sigma_j^2 \right]_+.$$

而经验版用 Monte Carlo 估计:

$$\hat{r}_{\text{MC}}(M; k, p, h) = \frac{1}{R} \sum_{r=1}^R \frac{\langle M, T_{h,q}(M; \Omega^{(r)}) \rangle}{\|M\|_*}.$$

B.9 检查的是:

k, p, h 变大时, expected progress 是否系统性改善; 经验平均 progress 是否至少与 theorem lower bound 同趋势。

注意: B.9 第 (ii) 部分给出的显式下界主要体现 k, p, h , 它本身是一个偏粗的趋势型 bound, 不适合拿来做 tightness 验证。  MuonNesterov (1)

(g) batch noise proxy

文档的 Lemma 3.3 说明 mini-batch noise 会随着 B_{batch} 增大而下降。实验里可以这样估:

固定模型参数和数据位置, 取 R 个相互独立的 mini-batch (大小都为 B_{batch}), 算出对应梯度估计 $G^{(1)}, \dots, G^{(R)}$ 。

用

$$G_{\text{ref}} = \frac{1}{R} \sum_{r=1}^R G^{(r)}$$

或者一个 ultra-large batch 梯度当参考, 然后定义

$$\|G^{(r)} - G_{\text{ref}}\|_2 \leq \frac{1}{\sqrt{R}} \sum_{r=1}^R \|G^{(r)} - G_{\text{ref}}\|_2^2$$

如果你想更贴定理，也可以计算

$$V_\alpha(B_{\text{batch}}) = \frac{1}{R} \sum_{r=1}^R \|G^{(r)} - G_{\text{ref}}\|_F^\alpha.$$

这个量代表：**随机梯度噪声有多大**。

它用于支持 Lemma 3.3 以及 A.14/A.16/A.17 里“batch 和 inexactness 共同影响收敛”的叙事。

 MuonNesterov (1)

 MuonNesterov (1)

2. 实验 1: 检查 inexact polar assumption 是否成立

对应 assumption / theorem

- Assumption 3.5 / A.9
- B.5 (randomized compressed cubic NS)
- B.7 (general compressed solver lifting)
- B.9 的 EA1 / EA2 (对 Gaussian randomized cubic)

 MuonNesterov (1)

 MuonNesterov (1)

 MuonNesterov (1)

要 check 的东西

- $\hat{\delta}$: 最终 lifted 方向的 progress loss
- $\hat{\rho}$: 最终 lifted 方向的 operator-norm inflation

这个东西是什么

这两个量就是 inexact polar 假设里真正需要的量：

$\hat{\delta}$ 小，表示 $T(M)$ 仍然和 M 高度对齐；

$\hat{\rho}$ 小，表示 $T(M)$ 没有把步长方向放大得太夸张。

具体怎么计算

对每个保存的层/step：

1. 取当前 M
2. 用 randomized method 得到 Q 、 $B = Q^\top M$ 、 $S(B)$
3. 构造 $T(M) = QS(B)$
4. 计算

$$\hat{\delta} = 1 - \frac{\langle M, T(M) \rangle}{\|M\|_*}, \quad \hat{\rho} = \max(0, \|T(M)\|_{op} - 1).$$

对于 solver family：

- cubic
- theoretical quintic
- empirical quintic
- polar express

都用同样定义统一算。

注意：empirical quintic 和 polar express 在这篇稿子里没有直接 theorem，所以这里是“同一指标下的公平比较”，不是 theorem verification。文档自己也把这些 solver 列成要比较的对象。  MuonNesterov (1)

画什么图

1. 箱线图 / violin plot：不同 solver 的 $\hat{\delta}$ 分布
2. 箱线图 / violin plot：不同 solver 的 $\hat{\rho}$ 分布
3. 折线图： $\hat{\delta}$ 随 q 的变化
4. 折线图： $\hat{\rho}$ 随 q 的变化
5. 训练过程曲线：不同训练阶段（early / mid / late）的 $\hat{\delta}, \hat{\rho}$

这个实验用来干什么

- 先回答 randomized solver 是否满足理论接口
- 再看哪个 solver 的 $(\hat{\delta}, \hat{\rho})$ -cost 最优
- 给后面的 default solver 选择提供第一轮筛选

3. 实验 2：检查 B.5 / B.7 的误差分解是否成立

对应 assumption / theorem

- B.5：cubic randomized compressed NS 的精确误差分解
- B.7：一般 compressed solver 的 lifting theorem  MuonNesterov (1)  MuonNesterov (1)

要 check 的东西

- ξ_Q ：子空间损失
- $\hat{\delta}_B$ ：compressed solver 自身误差
- $\hat{\delta}$ ：lift 回原空间后的总误差
- 分解残差 $e_{\hat{\delta}}^{B.5}$ 、 $e_{\hat{\delta}}^{B.7}$ 、 $e_{\hat{\rho}}^{B.7}$

这个东西是什么

这是 randomized 理论里最重要的一步：

总误差 = 子空间损失 + 压缩 solver 误差

更精确地说是

$$\delta = 1 - (1 - \xi_Q)(1 - \delta_B).$$

也就是说, randomized 方法变差到底是因为:

- rank 太小导致 ξ_Q 大
还是
- solver 太差导致 δ_B 大
这个实验会直接告诉你。

具体怎么计算

对 cubic (严格对应 B.5)

计算

$$\xi_Q = 1 - \frac{\|P_Q M\|_*}{\|M\|_*}, \quad \hat{\delta}_B = 1 - \frac{\langle B, Z_q \rangle}{\|B\|_*},$$
$$\hat{\delta} = 1 - \frac{\langle M, Q Z_q \rangle}{\|M\|_*}.$$

然后算

$$e_{\delta}^{B.5} = \left| \hat{\delta} - (1 - (1 - \xi_Q)(1 - \hat{\delta}_B)) \right|.$$

对 general solver (对应 B.7)

计算

$$\hat{\delta}_B = 1 - \frac{\langle B, S(B) \rangle}{\|B\|_*}, \quad \hat{\rho}_B = \max(0, \|S(B)\|_{op} - 1).$$

再算

$$e_{\delta}^{B.7} = \left| \hat{\delta} - (1 - (1 - \xi_Q)(1 - \hat{\delta}_B)) \right|, \quad e_{\rho}^{B.7} = |\hat{\rho} - \hat{\rho}_B|.$$

画什么图

1. 散点图: x 轴 = 由 B.5/B.7 预测的总 δ , y 轴 = 实测 $\hat{\delta}$, 画 $y = x$
2. 折线图: ξ_Q 随 rank 变化
3. 折线图: $\hat{\delta}_B$ 随 q 变化
4. 堆叠条形图: 总误差分成

$$\xi_Q + (1 - \xi_Q)\hat{\delta}_B$$

两部分分别占多少

这个实验用来干什么

- 直接 support B.5 / B.7
- 分清 randomized 方法的误差来源
- 指导你优先调 rank 还是优先调 solver/q

4. 实验 3: randomized subspace 参数 sweep (k, p, h)

对应 assumption / theorem

- Corollary B.6
- Theorem B.9 (Gaussian randomized subspace + cubic)  MuonNesterov (1)
-  MuonNesterov (1)

要 check 的东西

- ξ_Q : subspace loss
- $\hat{r}_{\text{MC}}(M; k, p, h)$: 经验平均 progress
- $r_{\text{B9}}^{\text{lb}}(M; k, p, h)$: B.9 的 lower bound
- γ_k : 谱 gap ratio

这个东西是什么

B.9 想说的是:

Gaussian randomized subspace 的质量由 k, p, h 和谱结构共同决定。

- k 大: 抓到更多主子空间
- p 大: oversampling 更稳
- h 大: power iteration 把谱间距放大, 更容易抓住 top subspace

具体怎么计算

这一组实验必须用 Gaussian sketch, 因为 B.9 的 theorem 就是写给 Gaussian Ω 的。

具体流程:

1. 固定一个 M 快照
2. 给定一组 (k, p, h) , 令 $\ell = k + p$
3. 重复 R 次 (建议 $R = 16$ 或 32):
 - 采样 $\Omega^{(r)} \sim \mathcal{N}(0, 1)^{d \times \ell}$

- 构造

$$Y = (MM^\top)^h M \Omega^{(r)}, \quad Q^{(r)} = \text{orth}(Y)$$

- 取 $B^{(r)} = (Q^{(r)})^\top M$
- 用 **固定** q 的 cubic NS (建议先固定 $q = 5$) 得到 $T_{h,q}(M; \Omega^{(r)})$
- 计算

$$r^{(r)} = \frac{\langle M, T_{h,q}(M; \Omega^{(r)}) \rangle}{\|M\|_*}$$

4. Monte Carlo 平均:

$$\hat{r}_{\text{MC}} = \frac{1}{R} \sum_{r=1}^R r^{(r)}$$

5. 同时由 M 的 SVD 算出 σ_j 、 γ_k ，再计算

$$r_{\text{B9}}^{\text{lb}}(M; k, p, h) = \frac{1}{\sigma_1 \|M\|_*} \left[\sum_{j=1}^k \sigma_j^2 - \frac{k}{p-1} \gamma_k^{4h} \sum_{j>k} \sigma_j^2 \right]_+.$$

一个重要备注： B.9 第 (ii) 部分的显式下界主要体现 k, p, h ，本身并不适合拿来验证 q 的效果，所以这组实验里建议把 q 固定； q 的作用放到 solver 实验里单独测。  MuonNesterov (1)

参数网格

建议：

- $k/d \in \{1/16, 1/8, 1/4, 1/2\}$
- $p \in \{8, 16\}$
- $h \in \{0, 1, 2\}$
- $q = 5$ 固定

画什么图

1. 热图：x 轴 k/d ，y 轴 h ，颜色 = $\hat{r}_{\text{MC}}$
2. 折线图： ξ_Q 随 k/d 变化，颜色区分 h
3. 散点图：x 轴 = $r_{\text{B9}}^{\text{lb}}$ ，y 轴 = $\hat{r}_{\text{MC}}$
4. 折线图： $\hat{r}_{\text{MC}}$ 随 p 变化

这个实验用来干什么

- support B.6 / B.9 的“参数趋势”
- 决定 randomized sketch 的默认设置 (k, p, h)
- 判断是否值得做 power iteration

5. 实验 4: solver family $\times$ NS steps q 的比较

对应 assumption / theorem

- B.7 (general lifting)
- randomized cubic corollary
- randomized quintic corollary  MuonNesterov (1)  MuonNesterov (1)

要 check 的东西

- $\hat{\delta}_B, \hat{\rho}_B$: 压缩 solver 自身质量
- $\hat{\delta}, \hat{\rho}$: lift 之后整体质量
- 理论上界是否基本不被违反
- orthogonalization time / step

这个东西是什么

这是在回答一个很实际的问题:

用哪种 solver 最适合作为 default?

理论上:

- cubic 更“干净”, 因为 $\rho \approx 0$
- quintic 可能更快逼近, 但会引入 $\rho > 0$
- empirical quintic / polar express 没有这篇稿子里的直接 theorem, 所以它们主要是工程 default 候选

具体怎么计算

先固定 randomized sketch 的默认设置 (k, p, h) , 然后比较:

- cubic
- theoretical quintic
- empirical quintic
- polar express

对于 NS 类 solver, 再 sweep

$$q \in \{3, 5, 7\}.$$

对每个快照计算:

$$\hat{\delta}_B = 1 - \frac{\langle B, S(B) \rangle}{\|B\|_*}, \quad \hat{\rho}_B = \max(0, \|S(B)\|_{op} - 1).$$

如果算得动 exact polar $O(B)$, 再算

$$e_{\text{polar}} = \|S(B) - O(B)\|_{op}.$$

对于有 theorem 的 solver, 再算理论上界:

- cubic:

$$u_{\delta}^{(3)} = \xi_Q + (1 - \xi_Q)(1 - \ell_B^2)^{2^q}$$

- quintic:

$$u_{\delta}^{(5)} = \xi_Q + (1 - \xi_Q)(1 - \ell_B)^{2^q}, \quad u_{\rho}^{(5)} = (1 - \ell_B)^{2^q}.$$

画什么图

1. Pareto 图: x 轴 = orthogonalization time / step, y 轴 = final val metric
2. 折线图: 不同 solver 的 $\hat{\delta}_B$ 随 q 变化
3. 折线图: 不同 solver 的 $\hat{\rho}_B$ 随 q 变化
4. 散点图: 理论上界 vs 实测 $\hat{\delta} / \hat{\rho}$

这个实验用来干什么

- 选 default solver
- 判断 q 设成 3、5、7 哪个最合理
- 区分“理论最漂亮”和“实践最划算”的设置是不是同一个

6. 实验 5: randomized vs full-subspace

对应 assumption / theorem

- 文档第 4 节明确建议做 randomized NS vs full-subspace NS
- 理论解释主要靠 B.5 / B.7; 对最终优化表现的连接靠 A.14  MuonNesterov (1)
 MuonNesterov (1)  MuonNesterov (1)

要 check 的东西

- 最终 val loss / acc
- training loss
- wall-clock
- throughput
- orthogonalization time share
- $\xi_Q, \hat{\delta}, \hat{\rho}$

这个东西是什么

这是 randomized 方法最关键的工程问题：

它到底有没有在可接受精度损失下换来更高的训练效率。

具体怎么计算

比较两组：

- full-subspace default
- randomized default

要求：

- 相同模型
- 相同训练 budget
- 相同 β 、lr、wd tuning protocol
- 至少 3 个随机种子

记录：

- train loss vs step
- val metric vs step
- val metric vs wall-clock
- total training time
- tokens / examples to target metric
- 每 step orthogonalization 占总时间比例
- 诊断快照上的 $\xi_Q, \hat{\delta}, \hat{\rho}$

画什么图

1. 训练曲线：train loss vs step
2. 验证曲线：val metric vs wall-clock
3. 柱状图：最终指标、总时长、speedup
4. 表格： $\xi_Q, \hat{\delta}, \hat{\rho}$ 的均值 / 中位数 / 95 分位数

这个实验用来干什么

- 判断 randomized 版本是主结果还是只放 ablation
- 判断 randomized 掉点是不是主要来自 ξ_Q

7. 实验 6：batch size 与 stochastic noise

对应 assumption / theorem

- Assumption 3.2
- Lemma 3.3 (batch 增大, noise 降低)
- A.14 / A.16 / A.17 (stochastic noise 和 inexactness 一起进入优化界)

📄 MuonNesterov (1)

📄 MuonNesterov (1)

要 check 的东西

- $V_2(B_{\text{batch}})$ 或 $V_\alpha(B_{\text{batch}})$: 梯度噪声 proxy
- 端到端 final metric 随 B_{batch} 变化
- 小 batch 时 stochastic noise 是否主导, 大 batch 时 compression/inexactness 是否更显著

这个东西是什么

这组实验是把 randomized solver 的误差和 stochastic optimization 的误差放到一起看。batch 大了, 随机噪声应减小; 但如果 rank 太小或者 solver 太粗, compression error 仍可能成为瓶颈。

具体怎么计算

Part A: 静态噪声估计

固定模型状态 X , 对每个 batch size B_{batch} :

1. 取 R 个独立 mini-batch
2. 计算梯度估计 $G^{(1)}, \dots, G^{(R)}$
3. 令

$$G_{\text{ref}} = \frac{1}{R} \sum_{r=1}^R G^{(r)}$$

4. 计算

$$V_2(B_{\text{batch}}) = \frac{1}{R} \sum_{r=1}^R \|G^{(r)} - G_{\text{ref}}\|_F^2$$

如需更贴 theorem, 再算 $V_{1.5}$ 或 V_2

Part B: 端到端训练

在 fixed total tokens / fixed oracle calls 下 sweep

$$B_{\text{batch}} \in \{B_0, 2B_0, 4B_0, 8B_0\}.$$

为了公平, 对每个 batch size 用同样大小的小网格调 lr (比如 $\{0.5\times, 1\times, 2\times\}$)。

画什么图

1. log-log 图: $V_2(B_{\text{batch}})$ vs B_{batch}
2. 折线图: final val metric vs B_{batch}
3. 热图: x 轴 = B_{batch} , y 轴 = rank ratio, 颜色 = final val metric
4. 双轴图: batch size 对 gradient noise 与 final metric 的联合影响

这个实验用来干什么

- support Lemma 3.3
- support A.14/A.16/A.17 的 qualitative implication
- 决定 default batch size

8. 实验 7: Nesterov / β ablation

对应 assumption / theorem

这组实验**不主要是验证某个随机化 theorem**，而是支撑整篇 paper 的主叙事：

Muon with Nesterov momentum 在 randomized setting 下是否真的有收益。 文档主标题和主贡献都是这个方向。  MuonNesterov (1)

要 check 的东西

- Nesterov on / off
- $\beta \in \{0.90, 0.95, 0.98\}$
- 训练稳定性、最终指标、是否改变 $\hat{\delta}, \xi_Q$ 的分布

具体怎么计算

在 randomized default 设置下：

- 比较 Nesterov on / off
- 每种再 sweep β

记录：

- train / val 曲线
- $\hat{\delta}, \hat{\rho}, \xi_Q$
- 可选: γ_k 的分布（看 Nesterov 是否改变矩阵谱结构，从而影响 randomized sketch 质量）

画什么图

1. 训练曲线: Nesterov on / off

2. 柱状图：不同 β 的最终指标
3. 箱线图：不同 β 下的 $\hat{\delta}$ 或 ξ_Q

这个实验用来干什么

- 证明 randomized 版本下 Nesterov 依然值得保留
 - 选 default β
-

9. 实验 8：主结果与外部 baseline 对比

对应 assumption / theorem

这组实验**不是** theorem verification，而是 paper 必须有的“实用性”证明。

建议 baseline

最少一组可以是：

- AdamW
 - full-subspace Muon
 - 你们选出来的 randomized Muon default
 - Shampoo
 - SOAP
- 如果老师希望再加经典动量基线，可以加：
- SGD + Polyak momentum
 - SGD + Nesterov momentum

具体怎么做

- 每个 baseline 给相同 tuning budget
- 用相同训练 budget、相同数据和模型
- 至少 3 seeds

画什么图

1. 主表：final val metric、wall-clock、memory、throughput
2. 训练曲线：val metric vs wall-clock
3. Pareto 图：质量 vs 时间

这个实验用来干什么

- 证明你们选出来的 randomized default 真正有竞争力
- 让整篇 paper 不只停留在 theorem-support

10. 默认设置怎么选

我建议按下面顺序选 default：

第一步：先选 solver 与 q

用实验 4，选 Pareto frontier 上最靠前的 solver。

经验上可以这样定规则：

- 先筛掉 $\hat{\rho}$ 明显不稳的设置
- 再在剩下的设置里，选 orthogonalization time 更低、但 final val metric 与最佳配置差距很小的那个
- 如果 cubic 和 quintic 最终指标接近，优先选理论更干净的那个；如果 quintic 明显更快或更强，就选 quintic

第二步：再选 randomized sketch 的 (k, p, h)

用实验 3，建议规则是：

- 先看 $\hat{r}_{MC}$ 或 ξ_Q 是否已经进入饱和区
- 再选最小的 k 和最小的 h ，只要它的性能已经接近更大配置
- p 通常优先选较小但稳定的值，比如 8 或 16

第三步：再选 batch size

用实验 6，在 fixed budget 下选最优的 B_{batch} 。

第四步：确认 randomized vs full

用实验 5 最后确认：

- 如果 randomized 几乎不掉点但明显加速，就把 randomized 作为主方法
- 如果掉点明显但没有换来多少速度，就把 randomized 放成 ablation，不要当主结果

11. 我建议的论文写法

如果你想直接写进 paper，实验 section 可以按下面结构展开：

4.1 Diagnostic quantities

定义 $\hat{\delta}, \hat{\rho}, \xi_Q, \hat{\delta}_B, \hat{\rho}_B, \gamma_k, \ell_B, V_2(B_{\text{batch}})$

4.2 Theory-support experiments

- Inexact polar assumption check
- B.5 / B.7 decomposition check
- Gaussian randomized subspace ablation for k, p, h

4.3 Solver ablations

- cubic / theoretical quintic / empirical quintic / polar express
- q sweep

4.4 End-to-end randomized Muon

- randomized vs full
- batch size
- Nesterov ablation

4.5 Main comparison

- external baselines

如果你愿意，我下一条可以继续把这份 plan **改写成论文里的正式小节草稿**，直接用“4 Experimental Plan / 4.1 / 4.2 ...”的风格写。

Sources

